

| STAT230A Lecture 1 Introduction to Linear Regression

| 1 Introduction to Linear Regression

| 1.1 Data format

对于 individuals $i \in \{1, \dots, n\}$, 有

- Response / Outcome / Dependent variable:
 $Y_i, \quad i \in \{1, \dots, n\}$
- Covariate / Feature / Predictor / Independent variables:
 $X_{ij}, \quad i \in \{1, \dots, n\}, j \in \{1, \dots, p\}$

可以写作矩阵形式:

$$Y = \begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{bmatrix} \in \mathbb{R}^n, \quad X = \begin{bmatrix} X_{11} & X_{12} & \dots & X_{1p} \\ X_{21} & X_{22} & \dots & X_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ X_{n1} & X_{n2} & \dots & X_{np} \end{bmatrix} \in \mathbb{R}^{n \times p}$$

| 1.2 Regression 的形式

Regression 有以下形式:

$$y_i \approx \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_p x_{ip}, \quad \forall i \in \{1, \dots, n\}$$

也可以写作矩阵形式:

$$Y \approx XB$$

其中

$$B = \begin{bmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_p \end{bmatrix}$$

⚠ Remark: Simple regression ▾

- 若仅有一个 feature (不包含 intercept), 即 $y_i \approx \alpha + \beta x_i$, 则称其为 simple regression
- 通常情况下我们会考虑 intercept, 即对于 simple regression, 有

$$X = \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_m \end{bmatrix}$$

| 1.3 Regression 的优势

为什么使用 regression?

- **描述关系**: 描述 X 和 Y 的关系
- **预测参数**: 令 X 表示先前已知的数据, Y 表示随后观测的数据, 则可以利用 X 预测 Y

- **估计影响**: 估计 X 变化时对 Y 的影响 / 估计因果关系

为什么不使用其它工具?

- 实现更简单, 运行更快, 易于理解
- 是其他复杂工具的基础
- Conceptual models: 和 linear algebra 有紧密联系

☰ Example ▾

Francis Galton 数据:

- Y 表示 child height
- X 表示 weighted average of parent height

可以使用 simple regression $Y_i \approx \alpha + \beta X_i, \quad i \in \{1, \dots, n\}$