

STAT230A Lecture 5 Solving Regression

1 Solving Regression (Least Square)

Logic ▾

对 linear regression 的第一种理解基于 solving least square, 即 minimize $\sum_i (Y_i - \vec{x}_i^\top \vec{b})^2$, 由此可以解得 $\hat{\beta}$

Logic ▾

关于 simple least square 和 multiple least square 的更多论述, 见 [STA3001 Lecture 1-3](#), [STA3001 Lecture 14-15](#), [STA3001 Lecture 18-19](#)

1.1 Simple Regression

设定:

我们有以下数据:

- $Y_i \in \mathbb{R}, \quad \forall i \in \{1, \dots, n\}$
- $x_i \in \mathbb{R}, \quad \forall i \in \{1, \dots, n\}$

我们希望拟合出 best line (考虑 intercept) 来描述这些数据点, 即:

$$Y \approx \alpha + \beta X$$

其中 $\alpha, \beta \in \mathbb{R}$

求解:

我们考虑最小化 squared residuals, 即:

$$(\hat{\alpha}, \hat{\beta}) = \arg \min_{a, b} \sum_{i=1}^n (y_i - a - bx_i)^2$$

对目标函数求导, 有:

$$\frac{\partial}{\partial(a, b)} \sum_{i=1}^n (y_i - a - bx_i)^2 = \begin{bmatrix} -\sum_{i=1}^n 2(y_i - a - bx_i) \\ -\sum_{i=1}^n 2x_i(y_i - a - bx_i) \end{bmatrix}$$

令导数为 0, 有:

$$\begin{aligned} & \begin{bmatrix} -\sum_{i=1}^n 2(y_i - a - bx_i) \\ -\sum_{i=1}^n 2x_i(y_i - a - bx_i) \end{bmatrix} = \begin{bmatrix} 0 \\ 0\bar{x} \end{bmatrix} \\ \Rightarrow & \begin{bmatrix} -\frac{1}{n} \sum_{i=1}^n 2(y_i - a - bx_i) \\ -\frac{1}{n} \sum_{i=1}^n 2x_i(y_i - a - bx_i) \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \\ \Rightarrow & \begin{cases} \bar{y} - a - b\bar{x} = 0 & (1) \\ (\overline{xy}) - a\bar{x} - b(\overline{x^2}) = 0 & (2) \end{cases} \end{aligned}$$

令 (2) - (1), 有:

$$\begin{aligned} 0 &= (\overline{xy}) - \bar{x} \cdot \bar{y} - b(\overline{x^2}) + b(\bar{x})^2 \\ \Rightarrow \hat{\beta} &= \frac{(\overline{xy}) - \bar{x} \cdot \bar{y}}{(\overline{x^2}) - (\bar{x})^2} = \frac{\hat{\text{Cov}}(x, y)}{\hat{\text{Var}}[x]} \end{aligned}$$

代回 (1) 式, 有:

$$\hat{\alpha} = \bar{y} - \hat{\beta}\bar{x}$$

⚠ Remark ▾

Best fit line 一定经过点 $(\bar{x}, \bar{y})$

⚠ Remark: 与 (Sample) Correlation 的联系 ▾

Sample Correlation 的定义为:

$$\hat{\text{Corr}}(x, y) = \frac{\hat{\text{Cov}}(x, y)}{\sqrt{\hat{\text{Var}}[x]} \cdot \sqrt{\hat{\text{Var}}[y]}} \in [-1, 1]$$

令 $\hat{a}$ 和 $\hat{b}$ 表示 solutions to the best fit line, 代入它们的值, 则有:

$$\begin{aligned} y &\approx \hat{a} + \hat{b}x \\ &= (\bar{y} - \hat{b}\bar{x}) + \hat{b}x \\ &= \bar{y} + \hat{b}(x - \bar{x}) \\ &= \bar{y} + \frac{\hat{\text{Cov}}(x, y)}{\hat{\text{Var}}[x]}(x - \bar{x}) \end{aligned}$$

由此可以得到:

$$\frac{y - \bar{y}}{\sqrt{\hat{\text{Var}}[y]}} \approx \frac{\hat{\text{Cov}}(x, y)}{\sqrt{\hat{\text{Var}}[x]} \cdot \sqrt{\hat{\text{Var}}[y]}} \left(\frac{x - \bar{x}}{\sqrt{\hat{\text{Var}}[x]}} \right)$$

$$\Rightarrow \text{Standardized } y \approx \text{Sample Correlation} \times \text{Standardized } x$$

换言之, 若我们在 regression 之前对变量进行了 standardization, 则会得到:

- intercept = 0
- slope = sample correlation

| 1.2 Multiple Regression

设定:

我们有以下数据:

- $Y_i \in \mathbb{R}, \quad \forall i \in \{1, \dots, n\}$
- $x_i \in \mathbb{R}^p, \quad \forall i \in \{1, \dots, n\}$

我们希望拟合出 best hyperplane 来描述这些数据点, 即:

$$Y \approx X\beta$$

其中:

- $X \in \mathbb{R}^{n \times p}$ 为 design matrix
- $\beta \in \mathbb{R}^p$

求解:

我们考虑最小化 squared residuals, 即:

$$\hat{\beta} = \arg \min_{b \in \mathbb{R}^p} \frac{1}{n} \sum_{i=1}^n (y_i - x_i^\top b)^2$$

对目标函数求导, 有:

$$\begin{aligned}\frac{\partial}{\partial b} \sum_{i=1}^n (y_i - x_i^\top b)^2 &= -2 \sum_{i=1}^n x_i (y_i - x_i^\top b) \\ &= \begin{bmatrix} -2 \sum_{i=1}^n x_{i1} (y_i - x_i^\top b) \\ -2 \sum_{i=1}^n x_{i2} (y_i - x_i^\top b) \\ \vdots \\ -2 \sum_{i=1}^n x_{ip} (y_i - x_i^\top b) \end{bmatrix} \in \mathbb{R}^p\end{aligned}$$

令导数为 0, 可以得到以下 **normal equations**:

$$\sum_{i=1}^n x_i y_i = \sum_{i=1}^n x_i x_i^\top \hat{\beta} \iff X^\top Y = X^\top X \hat{\beta}$$

若 $X^\top X$ 为 invertible, 则有:

$$\hat{\beta} = (X^\top X)^{-1} X^\top Y$$

⚠ Remark: 使用 Matrix Calculus ▾

Objective function $S(\beta)$ 可以写作:

$$\begin{aligned}S(\beta) &= \sum_{i=1}^n (y_i - x_i^\top \beta)^2 \\ &= \|y - X\beta\|_2^2 \\ &= (y - X\beta)^\top (y - X\beta) \\ &= y^\top y - 2\beta^\top X^\top y + \beta^\top X^\top X \beta\end{aligned}$$

对 β 求导, 有:

$$\frac{\partial S(\beta)}{\partial \beta} = -2X^\top y + 2X^\top X \beta$$

令其等于 0, 则可以得到 normal equations:

$$\begin{aligned}X^\top X \beta &= X^\top y \\ \Rightarrow \hat{\beta} &= (X^\top X)^{-1} X^\top y \quad (\text{若 } X^\top X \text{ invertible})\end{aligned}$$

| 2 Solving Regression (Geometric Intuition)

Logic ▾

对 linear regression 的第二种理解是基于 geometric intuition, 即 projection, 由此同样可以解得 $\hat{\beta}$

Logic ▾

关于 geometric intuition 与 hat matrix 的更多论述, 见 [STA3001 Lecture 18-19](#)

| 2.1 Definition: Feature Space 和 Case Space

Feature space (特征空间):

在先前的讨论中, 我们令:

- X 的每个 column (feature) 为 axis
- X 的每个 row (observation) 为 point
由此得到一个 $\mathbb{R}^p$ 中的 feature space

Case space (样本空间):

而另一种考虑是令:

- X 的每个 row (observation) 为 axis
- X 的每个 column (feature) 为 point
由此得到一个 $\mathbb{R}^n$ 中的 case space

| 2.2 Case Space 中的 Regression




FIGURE 3.1: The geometry of OLS

问题:

考虑使用 case space, 则我们可以将 regression 问题转换为:

求出 hyperplane $C(X)$ 中的一个点, 其为对 $\vec{Y}$ 的 best approximation (closest point), 即为 $\vec{Y}$ 在 $C(X)$ 上的投影

Remark: ▾

因此对 regression 的另一种理解为 **projection of $\vec{Y}$ into $C(X)$**

求解:

对于 $\mathcal{C}(X)$ 中的任意点, 我们可以将其写作 $X\beta$, 若其为 $\vec{Y}$ 在 $\mathcal{C}(X)$ 上的投影, 则满足:

$$\vec{X}_j \perp (\vec{Y} - X\hat{\beta}), \quad \forall j = 1, \dots, p$$

由此可以得出:

$$\begin{aligned} X^\top(Y - X\hat{\beta}) &= \vec{0} \\ \Rightarrow X^\top Y &= X^\top X \hat{\beta} && \text{(Normal Equations)} \\ \Rightarrow \hat{\beta} &= (X^\top X)^{-1} X^\top Y && \text{(若 } X^\top X \text{ invertible)} \end{aligned}$$

⚠ Remark: $X^\top X$ 不为 full rank 的情况 ∨

若 $X^\top X$ 不为 full rank, 则:

- $\hat{\beta}$ 有 infinitely many "best" choices
- 但 $\hat{Y}$ 仍然 well-defined 且 unique

⚠ Remark: 一个 Special Simple Case ∨

若:

$$X = [\vec{1}] \quad \Rightarrow \quad \hat{\beta} = \arg \min \sum_{i=1}^n (y_i - a)^2$$

则:

$$\hat{\beta} = (X^\top X)^{-1} X^\top Y = \frac{\sum_{i=1}^n y_i}{n} = \bar{y}$$

2.3 Definition: Hat Matrix

考虑:

$$\hat{Y} = X\hat{\beta} = X(X^\top X)^{-1} X^\top \vec{Y} =: H\vec{Y}$$

其中

$$H := X(X^\top X)^{-1} X^\top$$

被称为 **hat matrix**, 其满足:

- **Symmetric:** $H^\top = X(X^\top X)^{-1} X^\top = H$
- **Idempotent:** $HH = X(X^\top X)^{-1} X^\top X(X^\top X)^{-1} X^\top = X(X^\top X)^{-1} X^\top = H$

⚠ Remark: Hat Matrix 的性质 (补充) ∨

- $HX = X$
- 若考虑 intercept, 则 $H\vec{1} = \vec{1}$
- 若考虑 intercept, 则 $HJ = J$, 其中 J 为所有元素均为 1 的矩阵
- $I - H$ 同样为 orthogonal projection matrix, 投影至 $\mathcal{C}(X)^\perp$

2.4 Definition: Residual

Residual 被定义为:

$$\hat{\epsilon} := \vec{Y} - X\hat{\beta} = (I - H)\vec{Y}$$

由此可以对 $\vec{Y}$ 进行 decomposition:

$$\begin{aligned}\vec{Y} &= H\vec{Y} + (I - H)\vec{Y} \\ &= \hat{Y} + \hat{\varepsilon}\end{aligned}$$

Residual 有以下性质:

- $\hat{\varepsilon} \in \mathcal{C}(X)^\perp$, 即 $\hat{\varepsilon} \perp \mathcal{C}(X)$
- $\hat{\varepsilon}^\top X_j = 0 \Rightarrow \sum_{i=1}^n \hat{\varepsilon}_i x_{ij} \quad \forall j \in \{1, \dots, p\}$
- $\hat{\varepsilon}^\top \hat{y} = 0 \Rightarrow \sum_{i=1}^n \varepsilon_i \hat{y}_i = 0$

 **Remark:** 存在 intercept 时 $\hat{\varepsilon}$ 的性质 

考虑 intercept, 则 design matrix 被定义为:

$$X = \begin{bmatrix} \vec{1} & \vec{X}_2 & \dots & \vec{X}_n \end{bmatrix}$$

由于 $\hat{\varepsilon} \perp \mathcal{C}(X)$, 有 $\hat{\varepsilon}^\top \vec{1} = 0$, 因此

$$\sum_{i=1}^n \varepsilon_i = 0$$