

STAT230A Lecture 9 Normal Linear Model (Inference)

1 Inference on β under the Normal Linear Model

Logic ▾

几个常见的对于 β 的 inference question 为:

- β_j 是否为 0? 即 $H_0 : \beta_j = 0$ 或求出 β_j 的 confidence interval
- β_j 和 β_k 是否相等? 即 $H_0 : \beta_j = \beta_k$ 或求出 $\beta_j - \beta_k$ 的 confidence interval

Logic ▾

我们首先考虑 parameter 为 scalar 的情况, 即

$$H_0 : c^\top \beta = a \quad v.s. \quad H_1 : c^\top \beta \neq a$$

1.1 General Scalar Parameter

Settings:

令 $c \in \mathbb{R}^p$ 已知, 考虑对 $c^\top \beta \in \mathbb{R}$ 进行 inference

Example ▾

若 $c = e_j = (0, \dots, 0, 1, 0, \dots, 0)^\top$, 则 $c^\top \beta = \beta_j$

$c^\top \hat{\beta}$ 的分布:

对于 Normal linear model, $c^\top \hat{\beta}$ 的分布为:

$$c^\top \hat{\beta} \sim \mathcal{N}(c^\top \beta, c^\top [\sigma^2 (X^\top X)^{-1}] c)$$

Pivotal quantity:

若 σ^2 已知, 则可以由此得到一个 pivotal quantity:

$$\frac{c^\top \hat{\beta} - c^\top \beta}{\sqrt{\sigma^2 c^\top (X^\top X)^{-1} c}} \sim \mathcal{N}(0, 1)$$

但通常情况下 σ^2 未知, 则考虑使用 $\hat{\sigma}^2$ 替代 σ^2 以得到 pivotal quantity:

$$\frac{c^\top \hat{\beta} - c^\top \beta}{\sqrt{\hat{\sigma}^2 c^\top (X^\top X)^{-1} c}} \sim t_{n-p}$$

Proof: Pivotal Quantity 的分布 (σ^2 未知) ▾

可以将 pivotal quantity 改写为以下形式:

$$\frac{c^\top \hat{\beta} - c^\top \beta}{\sqrt{\hat{\sigma}^2 c^\top (X^\top X)^{-1} c}} = \frac{\frac{c^\top \hat{\beta} - c^\top \beta}{\sqrt{\sigma^2 c^\top (X^\top X)^{-1} c}}}{\sqrt{\frac{\hat{\sigma}^2}{\sigma^2}}}$$

此时有:

- 分子: $\frac{c^\top \hat{\beta} - c^\top \beta}{\sqrt{\sigma^2 c^\top (X^\top X)^{-1} c}} \sim \mathcal{N}(0, 1)$

- 分母: $\frac{\hat{\sigma}^2}{\sigma^2} \sim \frac{\chi_{n-p}^2}{n-p}$
- 由于 $\hat{\sigma}^2$ 与 $\hat{\beta}$ independent, 分子与分母 independent

因此根据 t distribution 的定义, 有:

$$\frac{c^\top \hat{\beta} - c^\top \beta}{\sqrt{\hat{\sigma}^2 c^\top (X^\top X)^{-1} c}} \sim t_{n-p}$$

Confidence interval:

因此有

$$\begin{aligned} \mathbb{P}(-t_{n-p, 1-\alpha/2} \leq \frac{c^\top \hat{\beta} - c^\top \beta}{\sqrt{\hat{\sigma}^2 c^\top (X^\top X)^{-1} c}} \leq t_{n-p, 1-\alpha/2}) &= 1 - \alpha \\ \Rightarrow \mathbb{P}(c^\top \hat{\beta} - t_{n-p, 1-\alpha/2} \cdot \hat{s}e_c \leq c^\top \beta \leq c^\top \hat{\beta} + t_{n-p, 1-\alpha/2} \cdot \hat{s}e_c) &= 1 - \alpha \end{aligned}$$

其中

$$\hat{s}e_c := \sqrt{\hat{\sigma}^2 c^\top (X^\top X)^{-1} c}$$

即 $c^\top \beta$ 的 confidence interval 为:

$$c^\top \hat{\beta} \pm t_{n-p, 1-\alpha/2} \cdot \hat{s}e_c$$

Hypothesis Testing:

考虑 hypothesis testing:

$$H_0 : c^\top \beta = a \quad v.s. \quad H_1 : c^\top \beta \neq a$$

Under H_0 , test statistics 满足:

$$\frac{c^\top \hat{\beta} - a}{\sqrt{\hat{\sigma}^2 c^\top (X^\top X)^{-1} c}} \sim t_{n-p}$$

因此, reject H_0 若:

$$\left| \frac{c^\top \hat{\beta} - a}{\hat{s}e_c} \right| := \left| \frac{c^\top \hat{\beta} - a}{\sqrt{\hat{\sigma}^2 c^\top (X^\top X)^{-1} c}} \right| \geq t_{n-p, 1-\alpha/2}$$

其中, $t_{n-p, 1-\alpha/2}$ 为 t distribution with degree of freedom $n-p$ 的 $1-\alpha/2$ quantile

Example: Galton Dataset

对于 Galton dataset, 有 $\hat{\beta} = (\hat{\alpha} \quad \hat{\beta}_0)^\top$, 我们希望求出 $\hat{\beta}_0$ 的 confidence interval

使用 $c = (0 \quad 1)^\top$, 则有:

$$c^\top \hat{\beta} = \hat{\beta}_0$$

此时

$$\begin{aligned} \hat{s}e_c &= \sqrt{\hat{\sigma}^2 c^\top (X^\top X)^{-1} c} \\ &= \hat{\sigma} \sqrt{[(X^\top X)^{-1}]_{22}} \\ &= \sqrt{\hat{\text{Var}}[\hat{\beta}_0]} \end{aligned}$$

因此 confidence interval 为:

$$\hat{\beta}_0 \pm t_{n-p, 1-\alpha/2} \cdot \sqrt{\hat{\text{Var}}[\hat{\beta}_0]}$$

接下来我们考虑 parameter 为 vector 的情况, 即

$$H_0 : C\beta = \vec{a} \quad v. s. \quad H_1 : C\beta \neq \vec{a}$$

其中 $C \in \mathbb{R}^{l \times p}$ 为 full rank, 即 $\text{rank}(C) = l \quad (l \leq p)$

1.2 General Vector Paramaters

Settings:

令 $C \in \mathbb{R}^{l \times p}$ 已知且为 full rank, 考虑对 $C\beta \in \mathbb{R}^l$ 进行 inference

Example ▾

若 $C = (I_k \quad 0_{p-k}) \in \mathbb{R}^{k \times p}$, $a = \vec{0}$, 则此时 H_0 为

$$C\beta = (\beta_1, \dots, \beta_k)^\top = \vec{0}$$

$C\hat{\beta}$ 的分布:

对于 Normal linear model, $C\hat{\beta}$ 的分布为:

$$C\hat{\beta} \sim \mathcal{N}_l(C\beta, C[\sigma^2(X^\top X)^{-1}]C^\top)$$

Pivotal quantity:

若 σ^2 已知, 则可以由此得到一个 pivotal quantity:

$$\frac{(C\hat{\beta} - C\beta)^\top [C(X^\top X)^{-1}C^\top]^{-1}(C\hat{\beta} - C\beta)}{\sigma^2} \sim \chi_l^2$$

但通常情况下 σ^2 未知, 则考虑使用 $\hat{\sigma}^2$ 替代 σ^2 以得到 pivotal quantity:

$$F := \frac{(C\hat{\beta} - C\beta)^\top [C(X^\top X)^{-1}C^\top]^{-1}(C\hat{\beta} - C\beta)}{l\hat{\sigma}^2} \sim F_{l, n-p}$$

Proof: Pivotal Quantity 的分布 (σ^2 未知) ▾

可以将 pivotal quantity 改写为以下形式:

$$\begin{aligned} F &= \frac{(C\hat{\beta} - C\beta)^\top [C(X^\top X)^{-1}C^\top]^{-1}(C\hat{\beta} - C\beta)}{l\sigma^2} \\ &= \frac{\frac{(C\hat{\beta} - C\beta)^\top [C(X^\top X)^{-1}C^\top]^{-1}(C\hat{\beta} - C\beta)}{l\sigma^2}}{\frac{\hat{\sigma}^2}{\sigma^2}} \end{aligned}$$

其中,

- 分子:

$$\frac{(C\hat{\beta} - C\beta)^\top [C(X^\top X)^{-1}C^\top]^{-1}(C\hat{\beta} - C\beta)}{l\sigma^2} \sim \frac{\chi_l^2}{l}$$

- 分母:

$$\frac{\hat{\sigma}^2}{\sigma^2} \sim \frac{\chi_{n-p}^2}{n-p},$$

- 由于 $\hat{\sigma}^2$ 与 $\hat{\beta}$ independent, 分子与分母 independent

因此根据 F distribution 的定义,

$$F = \frac{\frac{(C\hat{\beta} - C\beta)^\top [C(X^\top X)^{-1}C^\top]^{-1}(C\hat{\beta} - C\beta)}{l\hat{\sigma}^2}}{\frac{\hat{\sigma}^2}{\sigma^2}} \sim F_{l, n-p}$$

Confidence Interval:

对于 Normal linear model, 当 parameter 为 vector 时, confidence interval 形为 "椭圆", 在此情况下, 我们通常不使用 confidence interval 进行 inference

Hypothesis Testing:

考虑 hypothesis testing:

$$H_0 : C\beta = \vec{a} \quad v. s. \quad H_1 : C\beta \neq \vec{a}$$

其中 $C \in \mathbb{R}^{l \times p}$ 为 full rank, 即 $\text{rank}(C) = l$ ($l \leq p$)

Under H_0 , test statistics 满足:

$$F = \frac{(C\hat{\beta} - \vec{a})^\top [C(X^\top X)^{-1}C^\top]^{-1}(C\hat{\beta} - \vec{a})}{l\hat{\sigma}^2} \sim F_{l, n-p}$$

因此, reject H_0 若:

$$F = \frac{(C\hat{\beta} - \vec{a})^\top [C(X^\top X)^{-1}C^\top]^{-1}(C\hat{\beta} - \vec{a})}{l\hat{\sigma}^2} \geq F_{l, n-p, 1-\alpha}$$

其中, $F_{l, n-p, 1-\alpha}$ 为 F distribution with degrees of freedom l and $n - p$ 的 $1 - \alpha$ quantile

| 2 Inference on y_{n+1} under the Normal Linear Model

Logic ▾

已知 data $X \in \mathbb{R}^{n \times p}, Y \in \mathbb{R}^n$, 则我们可以进行 model fitting, 若此时我们有了一个新的 data x_{n+1} , 我们希望对 y_{n+1} 进行 inference

一个 good estimator for y_{n+1} 是 $x_{n+1}^\top \hat{\beta} =: \hat{y}_{n+1}$, 但此时 inference 将面对两个 uncertainty:

1. $\hat{\beta}$ is not β
2. Y_{n+1} is not $\mathbb{E}[Y_{n+1}]$

若我们忽视第二个 uncertainty, 则可以利用 general scalar parameter ($c = x_{n+1}$) 的结论, 求出 $\mathbb{E}[y_{n+1}] = x_{n+1}^\top \beta$ 的 confidence interval

若我们考虑 y_{n+1} , 则需要在 $x_{n+1}^\top \beta$ 的基础上额外考虑 ε_{n+1} 的 variability

| 2.1 Inference on y_{n+1}

Settings:

已知 data $X \in \mathbb{R}^{n \times p}, Y \in \mathbb{R}^n$, 且已知 $x_{n+1} \in \mathbb{R}^p$, 考虑对 future outcome $y_{n+1} \in \mathbb{R}$ 进行 inference

$y_{n+1} - x_{n+1}^\top \hat{\beta}$ 的分布:

对于 Normal linear model, 有:

- $y_{n+1} \sim \mathcal{N}(x_{n+1}^\top \beta, \sigma^2)$
- $x_{n+1}^\top \hat{\beta} \sim \mathcal{N}(x_{n+1}^\top \beta, \sigma^2 x_{n+1}^\top (X^\top X)^{-1} x_{n+1})$
- y_{n+1} 和 $x_{n+1}^\top \hat{\beta}$ 为 independent ($\hat{\beta}$ 取决于 $\{y_1, \dots, y_n\}$, 与 y_{n+1} independent)

因此,

$$y_{n+1} - x_{n+1}^\top \hat{\beta} \sim \mathcal{N}(0, \sigma^2(1 + x_{n+1}^\top (X^\top X)^{-1} x_{n+1}))$$

Pivotal quantity:

通常情况下 σ^2 未知, 则考虑使用 $\hat{\sigma}^2$ 替代 σ^2 以得到 pivotal quantity:

$$\frac{y_{n+1} - x_{n+1}^\top \hat{\beta}}{\sqrt{\hat{\sigma}^2(1 + x_{n+1}^\top (X^\top X)^{-1} x_{n+1})}} \sim t_{n-p}$$

Confidence Interval:

因此有

$$\begin{aligned} \mathbb{P}(-t_{n-p, 1-\alpha/2} \leq \frac{y_{n+1} - x_{n+1}^\top \hat{\beta}}{\sqrt{\hat{\sigma}^2(1 + x_{n+1}^\top (X^\top X)^{-1} x_{n+1})}} \leq t_{n-p, 1-\alpha/2}) &= 1 - \alpha \\ \Rightarrow \mathbb{P}(x_{n+1}^\top \hat{\beta} - t_{n-p, 1-\alpha/2} \cdot \hat{p}e_{n+1} \leq y_{n+1} \leq x_{n+1}^\top \hat{\beta} + t_{n-p, 1-\alpha/2} \cdot \hat{p}e_{n+1}) &= 1 - \alpha \end{aligned}$$

其中

$$\hat{p}e_{n+1} := \sqrt{\hat{\sigma}^2(1 + x_{n+1}^\top (X^\top X)^{-1} x_{n+1})} \quad (n+1^{\text{th}} \text{ prediction error})$$

即 y_{n+1} 的 confidence interval 为:

$$x_{n+1}^\top \hat{\beta} \pm t_{n-p, 1-\alpha/2} \cdot \hat{p}e_{n+1}$$

Hypothesis Testing:

考虑 hypothesis testing:

$$H_0 : y_{n+1} = a \quad v.s. \quad H_1 : y_{n+1} \neq a$$

Under H_0 , test statistics 满足:

$$\frac{a - x_{n+1}^\top \hat{\beta}}{\sqrt{\hat{\sigma}^2(1 + x_{n+1}^\top (X^\top X)^{-1} x_{n+1})}} \sim t_{n-p}$$

因此, reject H_0 若:

$$\left| \frac{a - x_{n+1}^\top \hat{\beta}}{\hat{p}e_{n+1}} \right| := \left| \frac{a - x_{n+1}^\top \hat{\beta}}{\sqrt{\hat{\sigma}^2(1 + x_{n+1}^\top (X^\top X)^{-1} x_{n+1})}} \right| \geq t_{n-p, 1-\alpha}$$

其中, $t_{n-p, 1-\alpha}$ 为 t distribution with degree of freedom $n-p$ 的 $1-\alpha$ quantile