

STAT230A Lecture 10 Heteroskedastic Linear Model (Definition)

Logic ▾

对于 Normal Linear Model, 我们假设:

- $\vec{Y} = X\beta + \vec{\varepsilon}$
- $\vec{\varepsilon} \sim \mathcal{N}(\vec{0}, \sigma^2 I_n)$

但有时该假设并不成立, 可能出现的情况包括:

- ε 不服从 Normal distribution
- $\text{Var}[\varepsilon_i] \neq \text{Var}[\varepsilon_j]$

此时我们需要考虑 Heteroskedastic Linear Model

1 Heteroskedastic Linear Model (HLM)

1.1 Definition: Heteroskedastic Linear Model (HLM)

令:

- x_i 为 **fixed** input vector
- y_i 为 **random** outcome
- β 为 unknown **fixed** parameter vector
- ε_i 为 unknown **random** variables

则 Heteroskedastic Linear Model 被定义为:

$$y_i = x_i^\top \beta + \varepsilon_i$$

其中,

- $\mathbb{E}[\varepsilon_i] = 0, \quad \forall i$
- $\text{Var}[\varepsilon_i] = \sigma_i^2 < \infty, \quad \forall i$
- $\varepsilon_i \perp \varepsilon_j, \quad \forall i \neq j$

⚠ Remark: Gauss-Markov Model 中的 Parameters ▾

在 Gauss-Markov Model 中, parameters 为 $\beta \in \mathbb{R}^p$ 和 $\sigma_1^2, \dots, \sigma_n^2$

⚠ Remark: Gauss-Markov Model, Normal Linear Model, 和 Heteroskedastic Linear Model 的关系 ▾

- Heteroskedastic Linear Model 包含了 Normal Linear Model
- Heteroskedastic Linear Model 包含了大部分 Gauss-Markov Model (Gauss-Markov Model 仅要求 random error uncorrelated)

⚠ Remark: Heteroskedastic linear model 在 inference 时的困难 ▾

相较于 Normal linear model, Heteroskedastic linear model 在 inference 时存在两个主要困难:

- $\hat{\beta}$ 的 variance 未知
- $\vec{\varepsilon}$ 和 $\hat{\beta}$ 的 distribution 未知

1.2 $\hat{\beta}$ 的分解

在 Heteroskedastic linear model 中, 对于 least square estimator $\hat{\beta} = (X^\top X)^{-1} X^\top Y$, 有:

$$\begin{aligned}\hat{\beta} &= (X^\top X)^{-1} X^\top Y \\ &= \left(\sum_{i=1}^n \underbrace{x_i x_i^\top}_{p \times p \text{ matrix}} \right)^{-1} \left(\sum_{i=1}^n \underbrace{x_i}_{\mathbb{R}^p \text{ vector}} \underbrace{y_i}_{\text{scalar}} \right) \\ &= \left(\sum_{i=1}^n x_i x_i^\top \right)^{-1} \left(\sum_{i=1}^n x_i x_i^\top \beta + \sum_{i=1}^n x_i \varepsilon_i \right) \\ &= \underbrace{\beta}_{\text{target parameter}} + \underbrace{\left(\sum_{i=1}^n x_i x_i^\top \right)^{-1} \left(\sum_{i=1}^n x_i \varepsilon_i \right)}_{\text{random estimation error}}\end{aligned}$$

定义:

$$\begin{aligned}B_n &:= \frac{1}{n} \sum_{i=1}^n x_i x_i^\top \quad (= \frac{1}{n} X^\top X \in \mathbb{R}^{p \times p}) \\ \vec{\xi}_n &:= \frac{1}{n} \sum_{i=1}^n x_i \varepsilon_i \quad (= \frac{1}{n} X^\top \vec{\varepsilon} \in \mathbb{R}^p)\end{aligned}$$

则:

$$\hat{\beta} - \beta = B_n^{-1} \vec{\xi}_n \quad (= (X^\top X)^{-1} X^\top \vec{\varepsilon})$$

1.3 $\vec{\xi}_n$ 的期望和方差

在 Heteroskedastic linear model 中, 对于 $\vec{\xi}_n = \frac{1}{n} \sum_{i=1}^n x_i \varepsilon_i \in \mathbb{R}^p$, 有:

Mean:

$$\mathbb{E}[\vec{\xi}_n] = \frac{1}{n} \sum_{i=1}^n \mathbb{E}[x_i \varepsilon_i] = 0$$

Variance:

$$\begin{aligned}\text{Cov}(\vec{\xi}_n) &= \text{Cov}\left(\frac{1}{n} \sum_{i=1}^n x_i \varepsilon_i\right) \\ &= \frac{1}{n^2} \text{Cov}\left(\sum_{i=1}^n x_i \varepsilon_i\right) \\ &= \frac{1}{n^2} \sum_{i=1}^n \text{Cov}(x_i \varepsilon_i) \quad (\varepsilon_i \text{ 为 independent}) \\ &= \frac{1}{n^2} \sum_{i=1}^n x_i \text{Var}[\varepsilon_i] x_i^\top \\ &= \frac{1}{n^2} \sum_{i=1}^n \sigma_i^2 x_i x_i^\top \\ &= \frac{M_n}{n}\end{aligned}$$

其中,

$$M_n := \frac{1}{n} \sum_{i=1}^n \sigma_i^2 x_i x_i^\top \in \mathbb{R}^{p \times p}$$

表示 average of $\text{Var}[x_i \varepsilon_i]$

△ Remark: 矩阵形式 (补充) ∨

也可以用矩阵形式推导:

Mean:

$$\mathbb{E}[\vec{\xi}_n] = \mathbb{E}\left[\frac{1}{n}X^\top \vec{\varepsilon}\right] = \frac{1}{n}X^\top \mathbb{E}[\vec{\varepsilon}] = 0$$

Variance:

$$\begin{aligned}\text{Cov}(\vec{\xi}_n) &= \text{Cov}\left(\frac{1}{n}X^\top \vec{\varepsilon}\right) \\ &= \frac{1}{n^2}X^\top \text{Cov}(\vec{\varepsilon})X \\ &= \frac{1}{n^2}X^\top \text{diag}(\sigma_1^2, \dots, \sigma_n^2)X \\ &= \frac{1}{n^2}X^\top \Omega X \quad (\Omega := \text{diag}(\sigma_1^2, \dots, \sigma_n^2)) \\ &= \frac{M_n}{n} \quad \left(M_n := \frac{1}{n}X^\top \Omega X\right)\end{aligned}$$

1.4 $\hat{\beta}$ 的期望和方差

在 Heteroskedastic linear model 中, 对于 least square estimator $\hat{\beta} = (X^\top X)^{-1}X^\top Y$, 有:

Mean:

$$\begin{aligned}\mathbb{E}[\hat{\beta}] &= \mathbb{E}[\beta + B_n^{-1}\vec{\xi}_n] \\ &= \beta + B_n^{-1}\mathbb{E}[\vec{\xi}_n] \\ &= \beta \quad (\text{unbiasedness})\end{aligned}$$

Variance:

$$\begin{aligned}\text{Cov}(\hat{\beta}) &= \text{Cov}(\hat{\beta} - \beta) \\ &= \text{Cov}(B_n^{-1}\vec{\xi}_n) \\ &= B_n^{-1}\text{Cov}(\vec{\xi}_n)B_n^{-1} \\ &= \frac{1}{n}B_n^{-1}M_nB_n^{-1}\end{aligned}$$

⚠ **Remark: 矩阵形式 (补充)** ▾

也可以使用矩阵形式:

$$\begin{aligned}\text{Cov}(\hat{\beta}) &= \text{Cov}(\hat{\beta} - \beta) \\ &= \text{Cov}((X^\top X)^{-1}X^\top \vec{\varepsilon}) \\ &= (X^\top X)^{-1}X^\top \text{Cov}(\vec{\varepsilon})X(X^\top X)^{-1} \\ &= (X^\top X)^{-1}X^\top \Omega X(X^\top X)^{-1}\end{aligned}$$

其中, $\Omega := \text{diag}(\sigma_1^2, \dots, \sigma_n^2)$

若 $\Omega = \sigma^2 I_n$, 则 $\text{Cov}(\hat{\beta}) = \sigma^2 (X^\top X)^{-1}$

💡 **Logic** ▾

注意到 $M_n = \frac{1}{n} \sum_{i=1}^n \sigma_i^2 x_i x_i^\top$ 为 function of σ_i^2 , 为未知量, 因此为了进行 inference, 我们需要估计 M_n 与 $\text{Cov}(\hat{\beta})$

由于有

$$\mathbb{E}[\varepsilon_i] = 0 \quad \Rightarrow \quad \sigma_i^2 = \text{Var}[\varepsilon_i] = \mathbb{E}[\varepsilon_i^2]$$

因此一种考虑方法是使用 ε_i 替代 σ_i , 即

$$\tilde{M}_n = \frac{1}{n} \sum_{i=1}^n \varepsilon_i^2 x_i x_i^\top$$

但 ε_i 同样为未知量, 因此考虑用 $\hat{\varepsilon}_i$ 替代 σ_i

1.5 $\text{Cov}(\hat{\beta})$ 的估计 (Sandwich Covariance Matrix)

在 Heteroskedastic linear model 中, $\text{Cov}(\hat{\beta})$ 的一个估计为 **sandwich covariance matrix**:

$$\hat{\text{Cov}}(\hat{\beta}) = \frac{1}{n} B_n^{-1} \hat{M}_n B_n^{-1}$$

其中

$$\hat{M}_n = \frac{1}{n} \sum_{i=1}^n \hat{\varepsilon}_i^2 x_i x_i^\top$$

Sandwich variance estimator 有时也被称作 Eicker-Huber-White estimator, 记作 $\hat{V}_{EHW}(\hat{\beta})$

🔗 Proof: Sandwich Variance Estimator 的 Validity ▾

当 $n \rightarrow \infty$ 时, 有

$$\tilde{M}_n \xrightarrow{p} M_n \quad \text{and} \quad \hat{M}_n - \tilde{M}_n \xrightarrow{p} 0 \quad \Rightarrow \quad \hat{M}_n \xrightarrow{p} M_n$$

⚠ Remark: 矩阵形式 (补充) ▾

也可以使用矩阵形式:

$$\hat{\text{Cov}}(\hat{\beta}) = (X^\top X)^{-1} X^\top \hat{\Omega} X (X^\top X)^{-1}$$

其中,

$$\hat{\Omega} := \begin{bmatrix} \hat{\varepsilon}_1^2 & & \\ & \ddots & \\ & & \hat{\varepsilon}_n^2 \end{bmatrix}$$

⚠ Remark: 提升小样本情况的准确性 ▾

对于 Sandwich variance estimator, 若 σ_i^2 的波动较大, 则 $\hat{M}_n$ 难以收敛到 M_n , 因此需要较大的 n 来确保其 estimation 的准确性

事实上, 可以通过将 $\hat{\Omega} = \text{diag}(\hat{\varepsilon}_1^2, \dots, \hat{\varepsilon}_n^2)$ 调整为 $\tilde{\Omega} = \text{diag}(\tilde{\varepsilon}_1^2, \dots, \tilde{\varepsilon}_n^2)$ 来提升 n 较小时的准确性

$\tilde{\varepsilon}_i$ 的几种常见选择如下:

- **HC0 estimator:** $\hat{\varepsilon}_i$
- **HC1 estimator:** $\frac{\hat{\varepsilon}_i}{\sqrt{n/(n-p)}}$
- **HC2 estimator:** $\frac{\hat{\varepsilon}_i}{\sqrt{1-h_{ii}}}$, 其中 $h_{ii} = (X(X^\top X)^{-1}X^\top)_{ii}$

其中 HC2 estimator 是一个不错的选择