

| STAT230A Lecture 12 Frisch-Waugh Lovell Theorem (Theorem)

| 1 Frisch-Waugh Lovell Theorem (FWL Theorem)

| 1.1 Setting: Long Regression 和 Short Regression

令:

- $Y = X\hat{\beta} + \hat{\varepsilon}$
- $k + l = p$
- $X = (X_1, X_2) \in \mathbb{R}^{n \times p}$, 其中 $X_1 \in \mathbb{R}^{n \times k}$, $X_2 \in \mathbb{R}^{n \times l}$
- $\hat{\beta} = \begin{bmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \end{bmatrix} \in \mathbb{R}^p$, 其中 $\hat{\beta}_1 \in \mathbb{R}^k$, $\hat{\beta}_2 \in \mathbb{R}^l$

则:

- **long regression** 为 $Y = X\hat{\beta} + \hat{\varepsilon} = X_1\hat{\beta}_1 + X_2\hat{\beta}_2 + \hat{\varepsilon}$
- **short regression** 为 $Y = X_2\tilde{\beta}_2 + \tilde{\varepsilon}$

🔄 Logic: 比较 $\hat{\beta}_2$ 和 $\tilde{\beta}_2$ ✓

我们希望研究 $\hat{\beta}_2$ 和 $\tilde{\beta}_2$ 是否相同

事实上它们通常是不同的, 这点根据以下 formula 可知

$$\begin{aligned}\tilde{\beta}_2 &= (X_2^\top X_2)^{-1} X_2^\top Y \\ \hat{\beta}_2 &= [(X^\top X)^{-1} X^\top Y]_{\text{last } l \text{ elements}}\end{aligned}$$

但我们仍然难以显式地进行比较, 因此我们希望得到 $\hat{\beta}_2$ 的显式表达式, 由此引出 Frisch-Waugh Lovell Theorem (FWL Theorem)

| 1.2 Theorem: Frisch-Waugh Lovell Theorem (FWL Theorem)

令:

- $Y = X\hat{\beta} + \hat{\varepsilon}$
- $X = (X_1, X_2) \in \mathbb{R}^{n \times p}$, 其中 $X_1 \in \mathbb{R}^{n \times k}$, $X_2 \in \mathbb{R}^{n \times l}$, $k + l = p$
- $\hat{\beta} = \begin{bmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \end{bmatrix} \in \mathbb{R}^p$, 其中 $\hat{\beta}_1 \in \mathbb{R}^k$, $\hat{\beta}_2 \in \mathbb{R}^l$

则:

$$\hat{\beta}_2 = [X_2^\top (I_n - H_1) X_2]^{-1} X_2^\top (I_n - H_1) Y$$

其中 $H_1 = X_1 (X_1^\top X_1)^{-1} X_1^\top$

⚠ Remark: 等价写法 1 ✓

也可以将 $\hat{\beta}_2$ 写作

$$\hat{\beta}_2 = (\tilde{X}_2^\top \tilde{X}_2)^{-1} \tilde{X}_2^\top Y$$

其中 $\tilde{X}_2 = (I_n - H_1) X_2$, 即 column-wise residuals of X_2 regressed on X_1

因此比较 $\hat{\beta}_2$ 和 $\tilde{\beta}_2$ 等价于比较 X_2 和 $\tilde{X}_2$

△ Remark: 等价写法 2 ∨

也可以将 $\hat{\beta}_2$ 写作

$$\hat{\beta}_2 = (\tilde{X}_2^\top \tilde{X}_2)^{-1} \tilde{X}_2^\top \tilde{Y}$$

其中

- $\tilde{X}_2 = (I_n - H_1)X_2$
- $\tilde{Y} = (I_n - H_1)Y$

由于 $I_n - H_1$ 为 idempotent, 因此是否对 Y 进行 transformation 不影响结果

△ Remark: Intuition (补充) ∨


整体层面的 intuition:

多元回归里某个变量的系数, 等于在 "剔除了其他变量可解释的部分之后", 这个变量对 Y 的单变量回归系数

公式层面的 intuition:

- $\tilde{X}_2 = (I_n - H_1)X_2$ 表示 X_2 的各列在 $\text{Col}(X_1)^\perp$ 上的投影, 即 X_2 的各列中无法被 X_1 (以最大限度进行的) 线性表示的部分
- $\tilde{Y} = (I_n - H_1)Y$ 表示 Y 在 $\text{Col}(X_1)^\perp$ 上的投影, 即 Y 中无法被 X_1 (以最大限度进行的) 线性表示的部分
- $\hat{\beta}_2 = (\tilde{X}_2^\top \tilde{X}_2)^{-1} \tilde{X}_2^\top \tilde{Y}$ 表示一个新的 regression, 其试图将 Y 无法被 X_1 表示的部分投影到 X_2 无法被 X_1 表示的部分张成的空间

几何层面的 intuition:



- 考虑二维情况, 有两种等价的方法得到 $\hat{\beta}_2$:
 - 直接将 y 投影到 $\text{Col}(X)$ 上
 - 先将 y 和 x_2 投影到 $\text{Col}(X_1)^\perp$ 上, 再在 $\text{Col}(X_1)^\perp$ 内部进行投影
- 由于将 x_2 投影到 $\text{Col}(X_1)^\perp$ 后, $\tilde{x}$ 张成的空间是 $\text{Col}(X_1)^\perp$ 的子空间, 因此第二次投影是在 $\text{Col}(X_1)^\perp$ 内部进行的, 因此将 $\tilde{y}$ 投影到 $\text{Span}(\tilde{x})$ 等价于将 y 直接投影到 $\text{Span}(\tilde{x})$ 上 (因为 y 在 $\text{Col}(X_1)$ 上的分量并不会起影响)

实现层面的 intuition:

- **Step 1: 对 X_2 的每一列做回归**
 - 对每个 j , fit:

$$X_2^{(j)} \sim X_1$$

- 取 residual, 记为 $\tilde{X}_2^{(j)}$
- 拼成新的设计矩阵:

$$\tilde{X}_2 = (I - H_1)X_2$$

- **Step 2: 用 "净化后的" 变量做回归**
- fit:

$$Y \sim \tilde{X}_2$$

- 得到的系数 = 原多元回归 $Y \sim X_1 + X_2$ 中的 $\hat{\beta}_2$

🔗 Proof: Algebraic Method ▾

由于 $\hat{\beta}_2$ 为 $\hat{\beta}$ 的后 l 位, 且

$$\hat{\beta} = (X^\top X)^{-1} X^\top Y = \begin{bmatrix} X_1^\top X_1 & X_1^\top X_2 \\ X_2^\top X_1 & X_2^\top X_2 \end{bmatrix}^{-1} \begin{bmatrix} X_1^\top Y \\ X_2^\top Y \end{bmatrix}$$

使用 block matrix inversion formula 并化简即可得到 $\hat{\beta}_2$ 的表达式

令

$$A = X_1^\top X_1, \quad B = X_1^\top X_2, \quad C = X_2^\top X_1, \quad D = X_2^\top X_2.$$

假设 A 可逆 (通常 X_1 full column rank), 记 Schur complement

$$S \equiv D - CA^{-1}B = X_2^\top X_2 - X_2^\top X_1 (X_1^\top X_1)^{-1} X_1^\top X_2.$$

则 block inverse 公式给出:

$$\begin{pmatrix} A & B \\ C & D \end{pmatrix}^{-1} = \begin{pmatrix} * & * \\ -S^{-1}CA^{-1} & S^{-1} \end{pmatrix}.$$

因此

$$\hat{\beta}_2 = (-S^{-1}CA^{-1} \quad S^{-1}) \begin{pmatrix} X_1^\top Y \\ X_2^\top Y \end{pmatrix} = -S^{-1}CA^{-1}X_1^\top Y + S^{-1}X_2^\top Y.$$

展开 C, A , 有:

$$\hat{\beta}_2 = S^{-1} \left(X_2^\top Y - X_2^\top X_1 (X_1^\top X_1)^{-1} X_1^\top Y \right).$$

注意到

$$H_1 \equiv X_1 (X_1^\top X_1)^{-1} X_1^\top, \quad M_1 \equiv I - H_1.$$

因此

$$X_2^\top Y - X_2^\top X_1 (X_1^\top X_1)^{-1} X_1^\top Y = X_2^\top (I - H_1) Y = X_2^\top M_1 Y,$$

以及

$$S = X_2^\top X_2 - X_2^\top X_1 (X_1^\top X_1)^{-1} X_1^\top X_2 = X_2^\top (I - H_1) X_2 = X_2^\top M_1 X_2.$$

代回即可得到

$$\hat{\beta}_2 = (X_2^\top M_1 X_2)^{-1} X_2^\top M_1 Y$$

🔗 Proof: Geometric Method ▾

对于 long regression

$$Y = X_1 \hat{\beta}_1 + X_2 \hat{\beta}_2 + \hat{\varepsilon}$$

有 $X^\top \hat{\varepsilon} = \vec{0}$, 即

- $X_1^\top \hat{\varepsilon} = \vec{0}$
- $X_2^\top \hat{\varepsilon} = \vec{0}$

对 long regression 等式两侧同乘 $I_n - H_1$, 其中 $H_1 = X_1(X_1^\top X_1)^{-1}X_1^\top$, 则有:

$$(I - H_1)Y = (I - H_1)X_1\hat{\beta}_1 + (I - H_1)X_2\hat{\beta}_2 + (I - H_1)\hat{\varepsilon}$$

其中, 根据 geometric intuition, 显然有:

- $(I - H_1)X_1\hat{\beta}_1 = (X_1 - X_1(X_1^\top X_1)^{-1}X_1^\top X_1)\hat{\beta}_1 = \vec{0}$ (将 $\text{Col}(X_1)$ 中的 X_1 投影到 $\text{Col}(X_1)^\perp$ 上)
- $(I - H_1)\hat{\varepsilon} = \hat{\varepsilon}$ (将 $\text{Col}(X_1, X_2)^\perp$ 中的 $\hat{\varepsilon}$ 投影到 $\text{Col}(X_1)^\perp$ 上))

因此 long regression 转换为:

$$\begin{aligned} (I - H_1)Y &= (I - H_1)X_2\hat{\beta}_2 + \hat{\varepsilon} \\ \Rightarrow X_2^\top (I - H_1)Y &= X_2^\top (I - H_1)X_2\hat{\beta}_2 && (\text{同乘 } X_2^\top, \text{ 且 } X_2^\top \hat{\varepsilon} = 0) \\ \Rightarrow \hat{\beta}_2 &= [X_2^\top (I - H_1)X_2]^{-1} X_2^\top (I - H_1)Y \end{aligned}$$

⚠ Remark: Invertibility ∨

使用 Schur complement 的基本性质, 我们有:

$$\begin{pmatrix} A & B \\ C & D \end{pmatrix} \text{ invertible} \iff A \text{ invertible and } D - CA^{-1}B \text{ invertible}$$

且在先前的 algebraic method proof 中, 我们有:

$$D - CA^{-1}B = X_2^\top (I - H_1)X_2$$

因此

$$X^\top X \text{ invertible} \iff X_2^\top (I - H_1)X_2 \text{ invertible}$$

🔗 Logic ∨

对于 $\hat{\varepsilon}(\hat{\beta}_j)$, 其为

- NLM: square root of $\hat{\sigma}^2(X^\top X)^{-1}$ 的 diagonal elements
- HLM: square root of $(X^\top X)^{-1}X^\top \hat{\Omega}X(X^\top X)^{-1}$ 的 diagonal elements

我们接下来开始关心 $\hat{\beta}_2$ 的 covariance matrix, 我们现在有两种求解 $\hat{\beta}_2$ 的方法:

- Fit long regression $Y \sim X_1 + X_2$
- Fit residualized regression $Y \sim \tilde{X}_2$, 其中 $\tilde{X}_2 := (I - H_1)X_2$

我们希望比较这两种方法得到的 $\hat{\beta}_2$ 的 covariance matrix 是否相同

| 1.3 Theorem: FWL Theorem 得到的 Standard Error

情况一: G-M Model 和 NLM

对于 Gauss-Markov Model 和 Normal Linear Model, 考虑两种求解 $\hat{\beta}_2$ 的方法:

- Fit long regression $Y \sim X_1 + X_2$
- Fit residualized regression $Y \sim \tilde{X}_2$, 其中 $\tilde{X}_2 := (I - H_1)X_2$

令两种方法得到的 $\hat{\beta}_2$ 的 covariance 分别记为:

- Long regression: $\hat{V}_2 := [\hat{\sigma}^2(X^\top X)^{-1}]_{\text{bottom right } l \times l \text{ submatrix}}$
- Residualized regression: $\tilde{V}_2 := \hat{\sigma}^2(\tilde{X}_2^\top \tilde{X}_2)^{-1}$

则:

$$\hat{V}_2 = \frac{n-l}{n-p} \tilde{V}_2$$

情况二: HLM

对于 Heteroskedastic Linear Model, 考虑两种求解 $\hat{\beta}_2$ 的方法:

- Fit long regression $Y \sim X_1 + X_2$
- Fit residualized regression $Y \sim \tilde{X}_2$, 其中 $\tilde{X}_2 := (I - H_1)X_2$

令两种方法得到的 $\hat{\beta}_2$ 的 covariance 分别记为:

- Long regression: $\hat{V}_2^{EHW} := [(X^\top X)^{-1} X^\top \hat{\Omega} X (X^\top X)^{-1}]_{\text{bottom right } l \times l \text{ submatrix}}$
- Residualized regression: $\tilde{V}_2^{EHW} := (\tilde{X}_2^\top \tilde{X}_2)^{-1} \tilde{X}_2^\top \tilde{\Omega} \tilde{X}_2 (\tilde{X}_2^\top \tilde{X}_2)^{-1}$

则:

$$\hat{V}_2^{EHW} = \tilde{V}_2^{EHW}$$

⚠ Remark: Intuition

对于 G-M Model 和 NLM, 之所以会存在比例系数, 是因为在估计 $\hat{\sigma}^2$ 和 $\hat{\sigma}^2$ 时, 其无偏估计量需要使用自由度修正, 即分母为 $n - \text{number of parameters}$, 对于 long regression 和 residualized regression, 其 parameters 数分别为 p 和 l

对于 HLM, 由于 $\hat{\Omega} = \text{diag}(\hat{\varepsilon}_i^2)$, 并没有使用自由度修正, 因此不存在比例系数