

1 FWL Theorem 的应用: Getting Rid of the Intercept

Logic

默认情况下, 我们会考虑 intercept, 即 design matrix 为 $X = [\mathbf{1} \quad X_{-1}]$, 但这会导致一些问题:

- not scientifically interesting
- asymmetry (影响 model selection)

我们希望在不用 intercept 的情况下, 得到 X 的 non-intercept columns 的 coefficient values

1.1 Getting rid of the Intercept

Settings:

- $X = [\vec{1} \quad X_{-1}]$, 对应的 coefficients 分别为 β_1 和 β_2
- $X_1 := \vec{1}$
- $X_2 := X_{-1}$

FWL theorem 的使用:

则使用 FWL theorem, 可以通过 fit $(I - H_1)Y \sim (I - H_1)X_2$ (或 $Y \sim (I - H_1)X_2$) 得到 $\hat{\beta}_2$, 其中

$$\begin{aligned} H_1 &= X_1(X_1^\top X_1)^{-1}X_1^\top \\ &= \vec{1}_n(\vec{1}_n^\top \vec{1}_n)^{-1}\vec{1}_n^\top \\ &= n^{-1} \begin{bmatrix} 1 & \cdots & 1 \\ \vdots & \ddots & \vdots \\ 1 & \cdots & 1 \end{bmatrix} \end{aligned}$$

因此 $H_1 Y = [\bar{Y} \quad \bar{Y} \quad \dots \quad \bar{Y}]^\top \in \mathbb{R}^n$

定义 centering matrix $C_n := I - H_1$, 则

$$C_n Y = \begin{bmatrix} Y_1 - \bar{Y} \\ Y_2 - \bar{Y} \\ \vdots \\ Y_n - \bar{Y} \end{bmatrix} \quad C_n X = \begin{bmatrix} \vec{X}_1 - \bar{X}_1 & X_2 - \bar{X}_2 \end{bmatrix}$$

因此 regress $Y - \bar{Y}$ on $X_2 - \bar{X}_2$ 即可直接得到 $Y \sim X$ 的 non-intercept coefficients

| 2 FWL Theorem 的 Application: F-Statistics

Logic ▾

对于 NLM, 我们可以 test $C\beta = \vec{0}$ 其中 $C \in \mathbb{R}^{l \times p}$, 并可以由此 test 是否某个 β' s 的 subset 均为 0

现在考虑 long regression $Y = X_1\beta_1 + X_2\beta_2 + \varepsilon$, 其中 $X_1 \in \mathbb{R}^{n \times k}$, $X_2 \in \mathbb{R}^{n \times l}$, 我们希望 test $H_0 : \beta_2 = 0$

| 2.1 F-Statistics (Using Residualized Model)

令 $C = [0_{l \times k} \quad I_l] \in \mathbb{R}^{l \times p}$, 则

$$\beta_2 = 0 \iff C\beta = 0$$

Original F-statistics:

使用 original F-statistics, 有

$$F = \frac{(C\hat{\beta})^\top [C(X^\top X)^{-1}C^\top]^{-1}C\hat{\beta}}{\hat{\sigma}^2 l} \sim F_{l, n-p} \quad (\text{under } H_0)$$

Residualized model 的 F-statistics:

考虑 residualized model $Y \sim \tilde{X}_2$, 此时 hypothesis 为 $H_0 : \beta_2 = 0$, F-statistics 为

$$\tilde{F} = \frac{\hat{\beta}_2^\top (\tilde{X}_2^\top \tilde{X}_2)^{-1} \hat{\beta}_2}{\hat{\sigma}_2^2 l} \sim F_{l, n-l} \quad (\text{under } H_0)$$

⚠ Remark: F 和 $\tilde{F}$ 的比较 ▾

事实上, $F = \tilde{F}$, 唯一的区别在于 degree of freedom, 原因在于估计 σ^2 时使用了不同的系数进行自由度修正

通常情况下, 我们仍然使用 $n - p$ 作为自由度

Logic ▾

假设我们不打算直接使用原来的 F-test, 并希望构建一个合理的 test statistic, 则比较 RSS 是一个合理的入手点

| 2.2 Alternative Way to Test β_2

考虑以下两个 regressions:

$$\begin{aligned} \text{Regression 1: } Y \sim X_1 + X_2 &\Rightarrow \begin{cases} \text{residuals: } \hat{\varepsilon}_i^{\text{full}} \\ \text{RSS: } RSS_{\text{full}} = \sum_{i=1}^n (\hat{\varepsilon}_i^{\text{full}})^2 \end{cases} \\ \text{Regression 2: } Y \sim X_1 &\Rightarrow \begin{cases} \text{residuals: } \hat{\varepsilon}_i^{\text{red}} \\ \text{RSS: } RSS_{\text{red}} = \sum_{i=1}^n (\hat{\varepsilon}_i^{\text{red}})^2 \end{cases} \end{aligned}$$

其中 $RSS_{\text{full}} \leq RSS_{\text{red}}$ (从几何角度考虑), 但在 $H_0 : \beta_2 = 0$ 下, RSS_{full} 和 RSS_{red} 应该相近, 由此可以根据 RSS 构建以下 test statistic:

$$\begin{aligned} F_{\text{ANOVA}} &= \frac{(RSS_{\text{red}} - RSS_{\text{full}})/l}{RSS_{\text{full}}/(n-p)} \\ &= \frac{(RSS_{\text{red}} - RSS_{\text{full}})/l}{\hat{\sigma}^2} \end{aligned}$$

⚠ Remark: Intuition ▾

对于 NLM 和 G-M Model,

- 在 H_0 下, 分子和分母的 expectation 均为 σ^2 , 因此 $F_{\text{ANOVA}} \approx 1$
- 在 H_1 下 (H_0 very false), 分子的 expectation 会远大于 σ^2 , 因此 $F_{\text{ANOVA}} \gg 1$

2.3 Theorem: $F_{\text{ANOVA}} = F_{\text{Wald}}$

$$F_{\text{ANOVA}} = F_{\text{Wald}}$$

Proof

Step 1: 改写 F_{ANOVA} 和 F_{Wald} :

可将 RSS_{full} 改写为以下形式:

$$\begin{aligned} RSS_{\text{full}} &= \sum_{i=1}^n (\hat{\epsilon}_i^{\text{full}})^2 \\ &= \hat{\epsilon}_{\text{full}}^\top \hat{\epsilon}_{\text{full}} \\ &= Y^\top (I - H) Y \end{aligned}$$

其中, $H = X(X^\top X)^{-1}X^\top$

类似地, 可将 RSS_{red} 改写为以下形式:

$$RSS_{\text{red}} = Y^\top (I - H_1) Y$$

其中, $H_1 = X_1(X_1^\top X_1)^{-1}X_1^\top$

因此 F_{ANOVA} 可被改写为:

$$\begin{aligned} F_{\text{ANOVA}} &= \frac{Y^\top (I - H_1) Y - Y^\top (I - H) Y}{l\hat{\sigma}^2} \\ &= \frac{Y^\top (H - H_1) Y}{l\hat{\sigma}^2} \end{aligned}$$

而对于 F_{Wald} , 其可被改写为:

$$\begin{aligned} F_{\text{Wald}} &= \frac{\hat{\beta}_2^\top (\tilde{X}_2^\top \tilde{X}_2)^{-1} \hat{\beta}_2}{l\hat{\sigma}^2} \quad (\text{FWL Theorem}) \\ &= \frac{Y^\top \tilde{X}_2 (\tilde{X}_2^\top \tilde{X}_2)^{-1} (\tilde{X}_2^\top \tilde{X}_2)^{-1} \tilde{X}_2^\top Y}{l\hat{\sigma}^2} \\ &= \frac{Y^\top \tilde{H}_2 Y}{l\hat{\sigma}^2} \end{aligned}$$

Step 2: 证明 $H - H_1 = \tilde{H}_2$

令 $X = [X_1 \ X_2]$, $X^\top X = \begin{bmatrix} A & B \\ C & D \end{bmatrix}$, 其中

$$A = X_1^\top X_1, \quad B = X_1^\top X_2, \quad C = X_2^\top X_1, \quad D = X_2^\top X_2.$$

则 Schur complement 为

$$\begin{aligned} S &:= D - CA^{-1}B \\ &= X_2^\top X_2 - X_2^\top X_1 (X_1^\top X_1)^{-1} X_1^\top X_2 \\ &= X_2^\top (I - H_1) X_2 \\ &= \tilde{X}_2^\top \tilde{X}_2 \end{aligned}$$

因此, 由 block matrix inversion formula, 有

$$(X^\top X)^{-1} = \begin{pmatrix} A^{-1} + A^{-1}BS^{-1}CA^{-1} & -A^{-1}BS^{-1} \\ -S^{-1}CA^{-1} & S^{-1} \end{pmatrix}.$$

因此

$$\begin{aligned} H &= [X_1 \ X_2] \begin{pmatrix} A^{-1} + A^{-1}BS^{-1}CA^{-1} & -A^{-1}BS^{-1} \\ -S^{-1}CA^{-1} & S^{-1} \end{pmatrix} \begin{pmatrix} X_1^\top \\ X_2^\top \end{pmatrix} \\ &= X_1(A^{-1} + A^{-1}BS^{-1}CA^{-1})X_1^\top + X_1(-A^{-1}BS^{-1})X_2^\top + X_2(-S^{-1}CA^{-1})X_1^\top + X_2S^{-1}X_2^\top \end{aligned}$$

其中,

$$\begin{aligned}X_1 A^{-1} X_1^\top &= X_1 (X_1^\top X_1)^{-1} X_1 = H_1 \\X_1 A^{-1} B S^{-1} C A^{-1} X_1^\top &= X_1 (X_1^\top X_1)^{-1} X_1^\top X_2 (\tilde{X}_2^\top \tilde{X}_2)^{-1} X_2^\top X_1 (X_1^\top X_1)^{-1} X_1^\top \\&= H_1 X_2 (\tilde{X}_2^\top \tilde{X}_2)^{-1} X_2^\top H_1 \\X_1 A^{-1} B S^{-1} X_2^\top &= X_1 (X_1^\top X_1)^{-1} X_1^\top X_2 (\tilde{X}_2^\top \tilde{X}_2)^{-1} X_2^\top = H_1 X_2 (\tilde{X}_2^\top \tilde{X}_2)^{-1} X_2^\top \\X_2 S^{-1} C A^{-1} X_1^\top &= X_2 (\tilde{X}_2^\top \tilde{X}_2)^{-1} X_2^\top X_1 (X_1^\top X_1)^{-1} X_1^\top = X_2 (\tilde{X}_2^\top \tilde{X}_2)^{-1} X_2^\top H_1 \\X_2 S^{-1} X_2^\top &= X_2 (\tilde{X}_2^\top \tilde{X}_2)^{-1} X_2^\top\end{aligned}$$

因此, 由于 $(I - H_1)X_2 = \tilde{X}_2$, 有

$$\begin{aligned}H &= H_1 - (H_1 X_2 (\tilde{X}_2^\top \tilde{X}_2)^{-1} X_2^\top - H_1 X_2 (\tilde{X}_2^\top \tilde{X}_2)^{-1} X_2^\top H_1) \\&\quad + (X_2 (\tilde{X}_2^\top \tilde{X}_2)^{-1} X_2^\top - X_2 (\tilde{X}_2^\top \tilde{X}_2)^{-1} X_2^\top H_1) \\&= H_1 - H_1 X_2 (\tilde{X}_2^\top \tilde{X}_2)^{-1} \tilde{X}_2^\top + X_2 (\tilde{X}_2^\top \tilde{X}_2)^{-1} \tilde{X}_2^\top \\&= H_1 + \tilde{X}_2 (\tilde{X}_2^\top \tilde{X}_2)^{-1} \tilde{X}_2^\top \\&= H_1 + \tilde{H}_2\end{aligned}$$

综上,

$$F_{\text{ANOVA}} = F_{\text{Wald}}$$

2.4 Corollary: F_{ANOVA} 的分布

对于 Normal Linear Model, 在 $H_0: \beta_2 = 0$ 下,

$$F_{\text{ANOVA}} \sim F_{l, n-p}$$

↪ Proof ∨

由于 $F_{\text{Wald}} = F_{\text{ANOVA}}$, 且在 H_0 下, 有

$$F_{\text{Wald}} \sim F_{l, n-p}$$

因此在 H_0 下有 $F_{\text{ANOVA}} \sim F_{l, n-p}$

3 FWL Theorem 的 Application: Cochran's Formula

Logic

考虑以下两个 regressions:

- Long regression: $Y = X_1\hat{\beta}_1 + X_2\hat{\beta}_2 + \hat{\varepsilon}$
- Short regression: $Y = X_2\tilde{\beta}_2 + \tilde{\varepsilon}_2$

假设 X_2 是某种 treatment, 我们希望研究其 effect, 但 X_1 未知, 因此我们只能使用 short regression 来替代 long regression, 我们希望知道 $\tilde{\beta}_2$ 是否和 $\hat{\beta}_2$ 相差很大

一个例子是研究 smoking (X_2) 是否会导致 cancer (Y), 但 gene (X_1) 数据未知 (数十年前还无法测量), 我们希望在以下两种 causal path 中作出判断:

- smoke $\rightarrow$ cancer (对应了 $\tilde{\beta}_2 > 0$ 的情况)
- gene $\rightarrow$ smoke, gene $\rightarrow$ cancer, smoke $\rightarrow$ cancer (对应了 $\hat{\beta}_2 = 0$ 的情况)

3.1 Theorem: Cochran's Formula (Omitted Variable Bias Formula)

考虑以下两个 regressions:

- Long regression: $Y = X_1\hat{\beta}_1 + X_2\hat{\beta}_2 + \hat{\varepsilon}$
 - Short regression: $Y = X_2\tilde{\beta}_2 + \tilde{\varepsilon}_2$
- 其中 $X_1 \in \mathbb{R}^{n \times k}$, $X_2 \in \mathbb{R}^{n \times l}$, $k + l = p$

令 X -on- X regression ($X_1 \sim X_2$, 共 k 个不同的 regression fits) 为:

$$X_1 = X_2\hat{\delta} + \hat{U}$$

其中 $\hat{\delta} \in \mathbb{R}^{l \times k}$, $\hat{U} \in \mathbb{R}^{n \times k}$

则:

$$\underbrace{\tilde{\beta}_2}_{\text{observed estimate}} = \underbrace{\hat{\beta}_2}_{\text{unknown good estimate}} + \underbrace{\hat{\delta}\hat{\beta}_1}_{\text{omitted variable bias}}$$

Remark: Intuition

若 X_1 中有一部分可以被 X_2 解释 (比例系数为 $\hat{\delta}$), 则当我们仅用 X_2 来拟合 (short regression) 时, 得到的 $\tilde{\beta}_2$ 中除了 $\hat{\beta}_2$, 还有一部分 $\hat{\beta}_1$ 的成分 (原本应属于 X_1)

Proof

将 X_1 与 X_2 的线性关系代入 long regression, 有

$$\begin{aligned} Y &= X_1\hat{\beta}_1 + X_2\hat{\beta}_2 + \hat{\varepsilon} \\ &= (X_2\hat{\delta} + \hat{U})\hat{\beta}_1 + X_2\hat{\beta}_2 + \hat{\varepsilon} \\ &= (\hat{\beta}_2 + \hat{\delta}\hat{\beta}_1)X_2 + (\hat{U}\hat{\beta}_1 + \hat{\varepsilon}) \end{aligned}$$

接下来仅需证明 $\hat{\beta}_2 + \hat{\delta}\hat{\beta}_1$ 是 short regression 中的 coefficient $\tilde{\beta}_2$, 即证明 $\hat{U}\hat{\beta}_1 + \hat{\varepsilon}$ orthogonal to X_2 的所有 columns

由于 $\hat{U}$ 为 $X_1 \sim X_2$ 的 residual ($X_2^\top \hat{U} = 0$), $\hat{\varepsilon}$ 为 $Y \sim X_1 + X_2$ 的 residual ($X_2^\top \hat{\varepsilon} = 0$), 有

$$X_2^\top (\hat{U}\hat{\beta}_1 + \hat{\varepsilon}) = X_2^\top \hat{U}\hat{\beta}_1 + X_2^\top \hat{\varepsilon} = 0$$

因此 $\tilde{\beta}_2 = \hat{\beta}_2 + \delta \hat{\beta}_1$