

1 Overfitting

Logic ▾

当 p 较大时, 常常会导致 overfitting, 此时 R^2 会出现问题

1.1 一个 Simulation 实验 (Fredman 1983)

重复以下步骤多次:

Step 1: 创建数据集

创建 random datasets, 其包括

- 100 observations
- 50 covariates

Step 2: 生成模型数据

生成

$$Y = X\beta + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, I_n)$$

其中

- $\beta = (\mu \quad 0 \quad \cdots \quad 0)^\top$
- $X = \begin{bmatrix} 1 & x_1^\top \\ 1 & x_2^\top \\ \vdots & \vdots \\ 1 & x_{100}^\top \end{bmatrix} \in \mathbb{R}^{100 \times 51}$

Step 3: 拟合模型

Fit $\hat{\beta} = (X^\top X)^{-1} X^\top Y$, 并计算 R^2

猜测 R^2 的分布:

注意到 R^2 的表达式为

$$R^2 = \frac{\sum(\hat{y}_i - \bar{y})^2}{\sum(y_i - \bar{y})^2}$$

由于在 underlying model 中 covariance 为 useless ($\beta_i = 0, \quad i > 1$), 一种猜测是 R^2 趋向于取较小的值

观测 R^2 的分布:

实际上, 对于 Normal Linear Model 与 Null Model, R^2 的分布与期望为:

$$R^2 \sim \text{Beta}\left(\frac{p-1}{2}, \frac{n-p}{2}\right)$$
$$\mathbb{E}[R^2] = \frac{p-1}{n-1}$$

当 $p = 51, n = 100$ 时, R^2 的分布会呈现钟形

△ Remark: R^2 的分布 ▾

由于 F statistics 和 R^2 为一一对应

$$F = \frac{R^2/(p-1)}{(1-R^2)/(n-p)} \iff R^2 = \frac{(p-1)F}{(p-1)F + (n-p)}$$

因此在 H_0 (NLM + Null Model) 下, 有

$$F \sim F_{p-1, n-p} \iff R^2 \sim \text{Beta}\left(\frac{p-1}{2}, \frac{n-p}{2}\right)$$

⚠ **Remark:** p 较大时的 R^2 ✓

当 p 很大时, bad regression 的 R^2 可能很大, 使其看起来为 useful model

🔄 **Logic** ✓

当 p 很大时, 还会导致 multicollinearity, 这同样会导致对 model parameter 的 inference 出现偏差

1.2 Theorem: Variance Decomposition of OLS Coefficients

令:

- $Y \in \mathbb{R}^n$
- $X \in \mathbb{R}^{n \times p}$
- $y_i = f(x_i) + \varepsilon_i, \quad \mathbb{E}[\varepsilon_i] = 0, \quad \text{Var}[\varepsilon_i] = \sigma_i^2$

则对于该 model, $\hat{\beta}$ 有

$$\text{Var}[\hat{\beta}_j] = \underbrace{\frac{\sigma^2}{\sum_{i=1}^n (x_{ij} - \bar{x}_j)^2}}_{\text{Var}[\hat{\beta}] \text{ in simple regression}} \cdot \underbrace{\frac{1}{1 - R_j^2}}_{\text{Variance Inflation Factor (VIF)}}$$

其中 R_j^2 为 regressing X_j on X 的其他 columns ($X_j \sim 1 + X_2 + \dots + X_{j-1} + X_{j+1} + \dots + X_p$) 的 R^2

⚠ **Remark:** Multicollinearity 的后果 ✓

由此可知, X_j 和其他 covariates 的相关性越高, $\hat{\beta}_j$ 的 variance 越高, β_j 的 confidence interval 越宽

因此, 即便 X_j 可能非常重要, 它与其他 X_k 的 correlation (**multicollinearity**) 可能 (通过增加 $\hat{\beta}_j$ 的 variance) 掩盖其重要性

| 2 Model Selection

| 2.1 Model Selection 的思路

Setting:

令:

- 共有 $\bar{p}$ 个 covariates (indices 为 $1, \dots, \bar{p}$)
- $\bar{p}$ 非常大
- $\bar{p} \leq n$

我们希望选出 $p \leq \bar{p}$ 个 covariates

思路:

1. 选择一个 criterion, 其能为每个 fitted model 给出一个 score
2. 对于每个 candidate model, 计算其 score, 并选出 score 最高的 model

Logic ▾

我们已经证实了 R^2 (以及 $\sum_{i=1}^n (y_i - \bar{y})^2$) 不是很好的 score 的选择, 因为其会随着 p 的增加而增加 (减小)

因此我们需要一些合适的 score, 接下来我们将介绍以下 scores:

- Adjusted R^2
- Information Criteria
- Leave-One-Out Cross-Validation Error

| 2.2 Adjusted R^2

定义 **Adjusted R^2** ($\bar{R}^2$) 为:

$$\bar{R}^2 = 1 - \frac{n-1}{n-p}(1 - R^2)$$

Remark ▾

随着 p 的增加, R^2 会增加, 但 $n-p$ 会减小, 由此避免 $\bar{R}^2$ 增加

由于 R^2 与 F-statistics 相关, $\bar{R}^2$ 同样与 F-statistics 相关

| 2.3 Information Criteria

Akaike Information Criterion (AIC):

$$\text{AIC} = n \log \frac{\text{RSS}}{n} + 2p$$

Bayes Information Criterion (BIC):

$$\text{BIC} = n \log \frac{\text{RSS}}{n} + p \log n$$

Remark: AIC/BIC 和 information theory 的关系 ▾

AIC 与 BIC 均来自于 information theory, 原理是衡量 distributions 之间的 divergence

⚠ Remark: AIC 与 BIC 的适用场景 ▾

- BIC 适用于在某个 model 为 right 的情景下找出 true model
- AIC 适用于在没有 model 为 right 的情景下 minimizing predictive error

| 2.4 Leave-One-Out Cross-Validation Error

定义 **predicted residual error sum square (PRESS)** 为:

$$\text{PRESS} = \sum_{i=1}^n \varepsilon_{[-i]}^2 = \sum_{i=1}^n \frac{\hat{\varepsilon}_i^2}{(1 - h_{ii})^2}$$

现在我们已经有了 score, 我们希望找出一个合适的方法来 search through 所有的 possible models ($\bar{p}$ predictors 的所有 subsets)

- 一种方法是迭代所有 subset models, 适用于 $\bar{p}$ 较小的情况, 但当 $\bar{p}$ 较大时 ($\bar{p} = 10 \Rightarrow 1024$ models), 需要考虑其他方法
- 另一种方法是考虑 F test, 但会有两个潜在的问题:
 - 对于 prediction 问题, F test 可能不会 ask the right question
 - F test 适用于比较 pairs of models, 不适用于从 subset 中选出一个

| 3 Forward / Backward / Stepwise Search

| 3.1 Forward Search

Step 1: Fit the intercept-only model $Y \sim 1$

Step 2: Fit all $\bar{p}$ one-variable models ($Y \sim 1 + X_j, j = 1, \dots, \bar{p}$), 并比较对应的 criterion, 选择其中最优的 model 进入下一步

Step 3: 重复 Step 2, 在当前 model 的基础上, 每次额外加入一个新的 variable (从剩余变量中选择), 并保留使 criterion 最优的 model

Step 4: 当继续添加 variable 不再提升 criterion 时, 算法终止

| 3.2 Backward Search

Step 1: Fit the full model $Y \sim 1 + X_1 + \dots + X_{\bar{p}}$

Step 2: Fit all $\bar{p}$ models with one variable removed (即 $Y \sim 1 + X_{-j}, j = 1, \dots, \bar{p}$), 并比较对应的 criterion, 选择其中最优的 model 进入下一步

Step 3: 重复 Step 2, 在当前 model 的基础上, 每次移除一个 variable (从当前变量中选择), 并保留使 criterion 最优的 model

Step 4: 当继续移除 variable 不再提升 criterion 时, 算法终止

| 3.3 Stepwise Search

Step 1: 从任意 initial model 开始

Step 2: 在当前 model 的基础上进行局部搜索:

- 尝试加入一个新的 variable (从剩余变量中选择)
- 尝试移除当前 model 中的某个 variable

分别 fit 所有 candidate models, 并比较对应的 criterion, 选择其中最优的 model 进入下一步

Step 3: 重复 Step 2, 在每一步选择使 criterion 最优的 model

Step 4: 当无法通过加入或移除 variable 来进一步提升 criterion 时, 算法终止