

STAT230A Lecture 21 Ridge Regression (Definition)

Logic ▾

对于上节 lecture 中提及的 model selection algorithm:

- 由于 problem 并不是 convex optimization, 该 greedy algorithms 并不能保证 optimal
- 由于 algorithm 需要遍历所有 subsets, 当 p 较大时 computationally infeasible

因此我们希望把问题转换为 convex problem (并不只是关于 picking variables), 这类思想对应的方法包括:

- Ridge regression
- Lasso regression
- Elastic net

1 Ridge Regression

Logic ▾

Ridge regression 的第一个 motivation 在于: 当 p 很大时, OLS 的求解 unstable

1.1 OLS 的问题

对于 OLS estimator

$$\hat{\beta}_{OLS} = (X^T X)^{-1} X^T Y$$

当 p 趋近于 n 时, $X^T X$ 的 eigenvalue 通常非常小 / 等于 0, 因此会导致 numerical issues, 即求解 $(X^T X)^{-1}$ unstable

Logic ▾

由于求解 $(X^T X)^{-1}$ 和 $X^T X$ 的 smallest eigenvalue / rank 相关

因此一种解决方法是增大 $X^T X$ 的 smallest eigenvalue, 从而使 $(X^T X)^{-1}$ 的求解更 stable

1.2 Ridge Regression 的 Estimator

Ridge regression 的 estimator 为:

$$\hat{\beta}_{ridge} = (X^T X + \lambda I_p)^{-1} X^T Y$$

其中 constant $\lambda > 0$

⚠ Remark: Ridge Estimator 对 Eigenvalues 的影响 ▾

对 $X^T X$ 作 eigendecomposition, 有

$$X^T X = P P^T, \quad \text{其中 } P = \begin{bmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_p \end{bmatrix}^{-1} P^T$$

因此有

$$\begin{aligned} X^T X + \lambda I_p &= P P^T + \lambda I_p \\ &= P P^T + \lambda P P^T \\ &= P (I + \lambda) P^T \end{aligned}$$

因此增加 λI_p 项使所有的 eigenvalues 增加了 λ

Logic ▾

Ridge regression 的另一个 motivation 在于: 由于 overfitting / unstable 问题常常对应了 big value of b_j , 我们希望避免 b_j 取较大的值

1.3 Ridge Regression 对应的 Optimization Problem

考虑 residual sum of squares:

$$\text{RSS}(\vec{b}) = \sum_{i=1}^n \left(y_i - \sum_{j=1}^p b_{ji} x_{ji} \right)^2$$

则:

- OLS: minimize RSS over all $\vec{b}$ vectors
- Ridge: minimize penalized RSS, 我们会惩罚 big value of b_j

即 Ridge regression 是在求解以下 Ridge problem:

$$\hat{\beta}_{\text{ridge}}^{(\lambda)} = \arg \min_{\vec{b}} \left[\text{RSS}(\vec{b}) + \lambda \sum_{j=1}^p b_j^2 \right]$$

求解该 Ridge problem, 有

$$\hat{\beta}_{\text{ridge}} = (X^T X + \lambda I_p)^{-1} X^T Y$$

△ Remark: 对 Ridge Problem 的改写 ▾

使用 optimization theory, 可以将 ridge problem 改写为另一种形式:

$$\begin{aligned} \hat{\beta} &= \arg \min \text{RSS}(\vec{b}) \\ \text{subject to } &\sum_{j=1}^p b_j^2 \leq t \quad \text{for some } t \end{aligned}$$

其中 t 与 λ 存在一一对应的关系

1.4 λ 的影响

对于 Ridge estimator $\hat{\beta}_{\text{ridge}} = (X^T X + \lambda I_p)^{-1} X^T Y$, 有

- $\lambda = 0$: 与 OLS 相同
- $\lambda = \infty$: 所有 coefficients 趋向于 0 (事实上只有 intercept 取到 0)

Logic ▾

对于 Ridge regression, 有几个细节需要处理:

- **Intercept**: 在之前的公式中, intercept 也被 penalized
- **Differently-scaled variables**: 由于 λ 是固定的, 且只有 1 个, 因此对不同 scale 的变量的缩放力度不统一

- **λ 的选取:** 为了选取最佳的 λ, 需要多次对不同的 λ 计算 $(X^T X + \lambda I)^{-1}$

1.5 Ridge Regression 的细节处理

处理 *intercept* 和 *differently-scaled variables*:

我们通常需要对 X 的 columns 进行 standardization (确保 mean 为 0 和 sample variance 为 1), 即:

- 对于 column j , 用 x_j 减去 $\bar{x}_j$
- 对于 column j , 将 x_j 除以 x_j 的 sample standard error

此时可以先直接求出 $\hat{\beta}_0 = \bar{y}$, 再对其他 β_j 添加 regularization 进行求解

△ Remark: Standardization 后的求解 ∨

由于 $\mathbf{1}^T X_j = n\bar{x}_j = 0$, 即 $\mathbf{1}$ 和 X 的其他 columns 正交, 此时求解目标函数时可以分别对 b_0 和其他 b_j 进行优化

$$\begin{aligned} L(\beta_0, \beta) &= \|Y - \beta_0 \mathbf{1} - X\beta\|^2 + \lambda \|\beta\|^2 \\ &= (Y - \beta_0 \mathbf{1} - X\beta)^T (Y - \beta_0 \mathbf{1} - X\beta) + \lambda \|\beta\|^2 \\ &= \|Y - \beta_0 \mathbf{1}\|^2 + \|X\beta\|^2 - 2(Y - \beta_0 \mathbf{1})^T X\beta + \lambda \|\beta\|^2 \\ &= \|Y - \beta_0 \mathbf{1}\|^2 + (\|X\beta\|^2 - 2Y^T X\beta + \lambda \|\beta\|^2) \\ &= f(\beta_0) + g(\beta) \end{aligned}$$

处理 λ 的选择:

我们可以使用 singular value decomposition 来为不同的 λ 计算 $\hat{\beta}_{\text{ridge}}$, 具体将会在下个 theorem 中展开

△ Remark: SVD for X and $X^T X$ ∨

令 $A \in \mathbb{R}^{n \times m}$ 为任意矩阵, 则其有 SVD:

$$A = UDV^T$$

其中,

- $U \in \mathbb{R}^{n \times n}$ 为 orthogonal matrix ($U^T U = I_p$)
- $V \in \mathbb{R}^{m \times m}$ 为 orthogonal matrix ($V^T V = I_p$)
- $D \in \mathbb{R}^{n \times m}$ 为 diagonal matrix, 且 diagonal elements (singular value) 非负

若对 X 进行 SVD, 则有

$$\begin{aligned} X &= UDV^T \\ \Rightarrow X^T X &= VDU^T UDV^T = VD^2 V^T \quad (X^T X \text{ 的 eigendecomposition}) \end{aligned}$$

利用 SVD, 我们可以求出 Ridge regression 的一些性质

1.6 Theorem: Ridge Estimator 的 SVD 表示

对于 Ridge regression, 有

$$\begin{aligned} \hat{\beta}_{\text{ridge}}^{(\lambda)} &= V \text{diag} \left(\frac{d_i}{d_i^2 + \lambda} \right) U^T Y \\ &= V \begin{bmatrix} \frac{d_1}{d_1^2 + \lambda} & & \\ & \ddots & \\ & & \frac{d_p}{d_p^2 + \lambda} \end{bmatrix} U^T Y \end{aligned}$$

由此我们可以先对 X 进行 SVD, 再代入不同的 λ 计算 $\hat{\beta}_{\text{ridge}}^{(\lambda)}$, 从而选取 λ

↪ Proof ∨

由于 $\hat{\beta}_{\text{ridge}}^{(\lambda)} = (X^\top X + \lambda I)^{-1} X^\top Y$, 使用 SVD, 则有

$$\begin{aligned} X^\top X + \lambda I &= V D^2 V^\top + V(\lambda I) V^\top = V(D^2 + \lambda I) V^\top \\ \Rightarrow (X^\top X + \lambda I)^{-1} &= V(D^2 + \lambda I)^{-1} V^\top \\ \Rightarrow \hat{\beta}_{\text{ridge}}^{(\lambda)} &= (X^\top X + \lambda I)^{-1} X^\top Y \\ &= V(D^2 + \lambda I)^{-1} V^\top V D U^\top Y \\ &= V(D^2 + \lambda I)^{-1} D U^\top Y \\ &= V \begin{bmatrix} \frac{d_1}{d_1^2 + \lambda} & & \\ & \ddots & \\ & & \frac{d_p}{d_p^2 + \lambda} \end{bmatrix} U^\top Y \end{aligned}$$

△ Remark: 和 OLS 的对比 ∨

对于 OLS, 使用 SVD, 有

$$\hat{\beta}_{OLS} = V \text{diag}\left(\frac{1}{d_i}\right) U^\top Y$$

由此可见, 相较于 OLS, ridge regression 在 SVD 坐标系中对每个方向做 shrinkage, 从而避免小奇异值带来的不稳定