

| STAT230A Lecture 22 Ridge Regression (Property)

| 1 Ridge Estimator 的性质

Logic ▾

在上个 lecture 中, 我们对 X 进行了 SVD, 从而得到

$$\begin{aligned} X &= UDV^\top \\ \Rightarrow X^\top X &= VDU^\top UDV^\top = VD^2V^\top \quad (X^\top X \text{ 的 eigendecomposition}) \end{aligned}$$

利用 SVD, 我们进一步求出了 Ridge estimator 的 SVD 表示

$$\begin{aligned} \hat{\beta}_{\text{ridge}}^{(\lambda)} &= V \text{diag} \left(\frac{d_i}{d_i^2 + \lambda} \right) U^\top Y \\ &= V \begin{bmatrix} \frac{d_1}{d_1^2 + \lambda} & & \\ & \ddots & \\ & & \frac{d_p}{d_p^2 + \lambda} \end{bmatrix} U^\top Y \end{aligned}$$

由此我们可以求出与 Ridge estimator 相关的一些统计量

接下来我们将假设 Gauss-Markov model assumption 成立:

- $Y = X\beta + \varepsilon$
- $\mathbb{E}[\varepsilon] = 0$
- $\text{Cov}(\varepsilon) = \sigma^2 I$

| 1.1 Ridge Estimator 的 Mean

在 Gauss-Markov model 中, 对于 Ridge estimator, 有

$$\begin{aligned} \mathbb{E}[\hat{\beta}_{\text{ridge}}^{(\lambda)}] &= \mathbb{E} \left[V \text{diag} \left(\frac{d_i}{d_i^2 + \lambda} \right) U^\top Y \right] \\ &= V \text{diag} \left(\frac{d_i}{d_i^2 + \lambda} \right) U^\top \mathbb{E}[Y] \\ &= V \text{diag} \left(\frac{d_i}{d_i^2 + \lambda} \right) U^\top X\beta \\ &= V \text{diag} \left(\frac{d_i}{d_i^2 + \lambda} \right) U^\top UDV^\top \beta \\ &= V \text{diag} \left(\frac{d_i^2}{d_i^2 + \lambda} \right) V^\top \beta \\ &\neq \beta \quad (\text{除非 } \lambda = 0) \end{aligned}$$

| 1.2 Ridge Estimator 的 Covariance

在 Gauss-Markov model 中, 对于 Ridge estimator, 有

$$\begin{aligned}
\text{Cov}(\hat{\beta}_{\text{ridge}}^{(\lambda)}) &= V \text{diag} \left(\frac{d_i}{d_i^2 + \lambda} \right) U^\top \text{Cov}(Y) U \text{diag} \left(\frac{d_i}{d_i^2 + \lambda} \right) V^\top \\
&= V \text{diag} \left(\frac{d_i}{d_i^2 + \lambda} \right) U^\top (\sigma^2 I) U \text{diag} \left(\frac{d_i}{d_i^2 + \lambda} \right) V^\top \\
&= \sigma^2 V \text{diag} \left(\frac{d_i^2}{(d_i^2 + \lambda)^2} \right) V^\top
\end{aligned}$$

注意到

$$\begin{aligned}
\text{Cov}(\hat{\beta}_{\text{ridge}}^{(\lambda)}) &= \sigma^2 V \text{diag} \left(\frac{d_i^2}{(d_i^2 + \lambda)^2} \right) V^\top \\
&\leq \sigma^2 V \text{diag} \left(\frac{1}{d_i^2} \right) V^\top \quad (\lambda = 0) \\
&= \sigma^2 (X^\top X)^{-1} \\
&= \text{Cov}(\hat{\beta}_{\text{OLS}})
\end{aligned}$$

由此可见, 相较于 OLS, $\hat{\beta}_{\text{ridge}}^{(\lambda)}$ 不保证 unbiasedness, 但是减小了 variance

1.3 Ridge Estimator 的 Mean-Squared Error

在 Gauss-Markov model 中, 对于 Ridge estimator, 有

$$\begin{aligned}
\text{MSE}(\hat{\beta}_{\text{ridge}}^{(\lambda)}) &= \|\text{Bias}(\hat{\beta}_{\text{ridge}}^{(\lambda)})\|^2 + \text{Tr}(\text{Cov}(\hat{\beta}_{\text{ridge}}^{(\lambda)})) \\
&= \underbrace{\lambda^2 \sum_{j=1}^p \frac{\gamma_j^2}{(d_j^2 + \lambda)^2}}_{\text{bias component}} + \underbrace{\sigma^2 \sum_{j=1}^p \frac{d_j^2}{(d_j^2 + \lambda)^2}}_{\text{variance component}}
\end{aligned}$$

其中 $\tilde{\gamma} = V^\top \beta$

由此可知:

- 若 λ 减小, 则 Bias 减小, Variance 增大
- 若 λ 增加, 则 Bias 增加, Variance 减小

↪ Proof ∨

对于 bias component, 有

$$\begin{aligned}
\text{Bias} &= V \text{diag} \left(\frac{d_i^2}{d_i^2 + \lambda} \right) V^\top \beta - V V^\top \beta \\
&= V \left[\text{diag} \left(\frac{d_i^2}{d_i^2 + \lambda} \right) - I \right] V^\top \beta \\
&= -V \text{diag} \left(\frac{\lambda}{d_i^2 + \lambda} \right) V^\top \beta \\
&= -V \text{diag} \left(\frac{\lambda}{d_i^2 + \lambda} \right) \gamma
\end{aligned}$$

由于 V 为 orthogonal, 不改变欧氏长度, 因此

$$\begin{aligned}
\|\text{Bias}\|^2 &= \left\| \text{diag} \left(\frac{\lambda}{d_i^2 + \lambda} \right) \gamma \right\|^2 \\
&= \sum_{j=1}^p \left(\frac{\lambda}{d_j^2 + \lambda} \gamma_j \right)^2 \\
&= \lambda^2 \sum_{j=1}^p \frac{\gamma_j^2}{(d_j^2 + \lambda)^2}
\end{aligned}$$

对于 variance component, 有

$$\begin{aligned}
\text{Variance component} &= \text{tr}(\text{Cov}(\hat{\beta}_{\text{ridge}}^{(\lambda)})) \\
&= \text{tr}\left(\sigma^2 V \text{diag}\left(\frac{d_i^2}{(d_i^2 + \lambda)^2}\right) V^T\right) \\
&= \sigma^2 \text{tr}\left(\text{diag}\left(\frac{d_i^2}{(d_i^2 + \lambda)^2}\right) V^T V\right) \\
&= \sigma^2 \text{tr}\left(\text{diag}\left(\frac{d_i^2}{(d_i^2 + \lambda)^2}\right)\right) \\
&= \sigma^2 \sum_{j=1}^p \frac{d_j^2}{(d_j^2 + \lambda)^2}
\end{aligned}$$

由此求出了 MSE 的表达式

Logic

接下来考虑 λ 的选取, 一种想法是最小化 MSE 的表达式, 但问题在于 β 和 σ^2 未知

一种解决方法是使用 OLS estimator $\hat{\beta}$ 和 $\hat{\sigma}^2$ 进行近似, 但很多情况下 (如 $p > n$ 的情况) OLS 并不可靠

现实中, 我们常常使用 cross-validation 来 minimize prediction error

1.4 使用 Cross-Validation 选取 λ

Step 1:

选取 a grid of λ values

Step 2:

对于每个 λ , 求出 $\hat{\epsilon}_{[-i]}(\lambda)$, $i = 1, \dots, n$, 并计算 $\text{PRESS} = \sum_{i=1}^n \hat{\epsilon}_{[-i]}^2(\lambda)$

Step 3:

选取能 minimize PRESS value 的 λ

Logic

为了高效计算 PRESS, 我们可以使用以下 leave-one-out formula 进行辅助

1.5 Theorem: Leave-One-Out (LOO) Formula

令:

$$\hat{Y}(\lambda) = X \hat{\beta}_{\text{ridge}}^{(\lambda)} = X(X^\top X + \lambda I)^{-1} X^\top Y$$

定义:

- $H(\lambda) = X(X^\top X + \lambda I)^{-1} X^\top$ 为 hat matrix (注意此处不为 projection matrix)
- $h_{ii}(\lambda) = H(\lambda)$ 的 i^{th} diagonal element
- $\hat{\epsilon}_i(\lambda) = Y_i - x_i^\top \hat{\beta}_{\text{ridge}}^{(\lambda)}$

则有:

$$\hat{\beta}_{[-i]}^{(\lambda)} = \hat{\beta}_{\text{ridge}}^{(\lambda)} - [1 - h_{ii}(\lambda)]^{-1} (X^\top X + \lambda I)^{-1} x_i \hat{\epsilon}_i(\lambda)$$

$$\hat{\varepsilon}_{[-i]} = \boldsymbol{y}_i - \boldsymbol{x}_i^\top \hat{\boldsymbol{\beta}}_{[-i]} = \frac{\hat{\varepsilon}_i(\boldsymbol{\lambda})}{1 - h_{ii}(\boldsymbol{\lambda})}$$