

| STAT230A Lecture 23 Ridge Regression (Relationship with PCA)

| 1 Ridge Regression 和 Principal Component Analysis

| 1.1 Principle Component Analysis

PCA 的 objective:

令 X 为 matrix with centered columns

$$X = \begin{bmatrix} x_1^\top \\ \vdots \\ x_m^\top \end{bmatrix} = [X_1 \quad \cdots \quad X_p] \in \mathbb{R}^{m \times p}$$

则 PCA (降低至 1 维) 的目标为: 求出 $v \in \mathbb{R}^p$ 使得 $\vec{x}_i^\top v \in \mathbb{R}$ 包含 x_i 的尽可能多的信息 (即保留尽可能多的 sample covariance)

PCA 的 problem formulation:

令:

$$\begin{aligned} \hat{\text{Cov}}(\vec{x}_i^\top v) &= v^\top \left(\frac{1}{n-1} \sum_{i=1}^n x_i x_i^\top \right) v \\ &\propto \vec{v}^\top (X^\top X) \vec{v} \\ &=: Q(\vec{v}) \end{aligned}$$

则 PCA 试图求解以下 optimization problem:

$$\begin{aligned} \max \quad & Q(\vec{v}) \\ \text{s.t.} \quad & \|\vec{v}\| = 1 \end{aligned}$$

PCA 的 solution:

求解以上 optimization problem, 可以得到:

- $X^\top X$ 的 largest eigenvalue 为 Q 的 best value
- 对应的 eigenvectors 为 best $\vec{v}$

对 X 做 SVD, 有

$$\begin{aligned} X &= UDV^\top \\ \Rightarrow X^\top X &= VD^2V^\top \quad (\text{eigendecomposition}) \end{aligned}$$

令:

- D^2 的 diagonal elements 为 $d_1^2 \geq d_2^2 \geq \cdots \geq d_p^2$
- V 的 columns 为 $\vec{v}_1, \vec{v}_2, \dots, \vec{v}_p$

则:

- $\vec{v}_1$ 为 best $\vec{v}$
- d_1^2 为 best value of Q
- $Xv_1 \in \mathbb{R}^n$ 为 best 1-dimensional approximation to X

⚠ Remark: Generalization ∨

若希望求出 best 2-dimensional approximation to X , 则在之前的基础上继续求解以下 problem:

$$\begin{aligned} \max \quad & Q(\vec{v}) \\ \text{s.t.} \quad & \|\vec{v}\| = 1, \vec{v} \perp \vec{v}_1 \end{aligned}$$

若希望求出 best k -dimensional approximation to X ($k < p$), 则只需要取

$$X[v_1 \ \cdots \ v_k] \in \mathbb{R}^{n \times k}$$

若 $k = p$, 则

$$\begin{aligned} X[v_1 \ \cdots \ v_p] &= XV \\ &= UDV^\top V \\ &= UD \\ &= [U_1 \ \cdots \ U_p] \begin{bmatrix} d_1 & & \\ & \ddots & \\ & & d_p \end{bmatrix} \end{aligned}$$

其中 XV 的 columns 被称为 principal components (某些教材中 $U_1, \dots, U_p$ 被称为 principal components)

1.2 Principal Components Regression (PCR)

Logic

考虑对 X 的前 p^* 个 principal components 做 regression, 即构建一个 smaller model, 但是包含了 X 的 most useful information

令 X 的 principal components 为 XV

考虑 regress Y on XV 的前 p^* 个 columns (principal components)

则有:

$$\begin{aligned} \hat{Y}_{\text{OLS}} &= X(X^\top X)^{-1} X^\top Y \stackrel{\text{SV}}{=} \sum_{j=1}^p (U_j^\top Y) U_j \\ \hat{Y}_{\text{PCR}} &= \sum_{j=1}^{p^*} (U_j^\top Y) U_j \end{aligned}$$

1.3 Ridge Regression 和 Principal Components Regression 的联系

考虑 ridge regression, 有

$$\begin{aligned} \hat{Y}_{\text{ridge}}(\lambda) &= X \hat{\beta}_{\text{ridge}}^{(\lambda)} \\ &= U \text{diag} \left(\frac{d_j^2}{d_j^2 + \lambda} \right) U^\top Y \\ &= [U_1 \ \cdots \ U_p] \text{diag} \left(\frac{d_j^2}{d_j^2 + \lambda} \right) \begin{bmatrix} U_1^\top Y \\ \vdots \\ U_p^\top Y \end{bmatrix} \\ &= \sum_{j=1}^p \left(\frac{d_j^2}{d_j^2 + \lambda} \right) (U_j^\top Y) U_j \end{aligned}$$

则 principal component regression 和 ridge regression 有以下联系:

- PCR 为 discrete shrinkage (截断了 p^* 之后的 components)
- Ridge 为 smooth shrinkage (通过 λ 控制所有 components, 且具有大 eigenvalue 的 components 贡献更多)

△ Remark: p 较大时与 Old-School Model Selection 的对比

Old-School Model Selection	Ridge Regression / PCR
non-convex optimization (fast or optimal)	convex optimization (fast and optimal)
model size 至多为 $p = n$	model size 可以为 $p > n$

Old-School Model Selection	Ridge Regression / PCR
通常得到 small models (部分 parameters 的 coefficients 为 0)	永远得到 large models ($\hat{\beta}_j \neq 0, j$)