

STAT230A Lecture 24 Lasso Regression

Logic ▾

在上个 lecture 中, 我们对比了 p 较大时 old-school model selection 与 Ridge regression 的表现, 我们希望能结合两者的优点, 即确保 convex problem 的同时最终得到 small models

一种满足需求的方法是 Lasso regression

1 Lasso Regression

1.1 Lasso Regression 对应的 Optimization Problem

Lasso (Least Absolute Shrinkage Selection Operator) regression 对应的 optimization problem 为:

$$\hat{\beta}_{\text{Lasso}}^{(\lambda)} = \arg \min_{\vec{b}} \left[\text{RSS}(\vec{b}) + \lambda \sum_{j=1}^p |b_j| \right]$$

△ Remark: 对 Lasso Problem 的改写 ▾

使用 optimization theory, 可以将 Lasso problem 改写为另一种形式:

$$\begin{aligned} \hat{\beta} &= \arg \min \text{RSS}(\vec{b}) \\ \text{subject to } \sum_{j=1}^p |b_j| &\leq t \quad \text{for some } t \end{aligned}$$

其中 t 与 λ 存在一一对应的关系


1.2 Lasso Regression 的 Geometry

考虑 $p = 2$ 的情况,

对于任意 $\vec{b}$, RSS 可以写作:

$$\begin{aligned} \text{RSS}(\vec{b}) &= (Y - \hat{Y}_{\vec{b}})^\top (Y - \hat{Y}_{\vec{b}}) \\ &= (Y - X\vec{b})^\top (Y - X\vec{b}) \\ &= (Y - X\hat{\beta}_{\text{OLS}})^\top (Y - X\hat{\beta}_{\text{OLS}}) + (\vec{b} - \hat{\beta}_{\text{OLS}})^\top X^\top X (\vec{b} - \hat{\beta}_{\text{OLS}}) \end{aligned}$$

因此 $\text{RSS}(\vec{b})$ 可以表示为以下 contour:



考虑 Ridge problem 和 Lasso problem, 它们分别对 $\vec{b}$ 设置了 constraints, 因此可以表示为:




FIGURE 15.1: Lasso with a sparse solution




FIGURE 15.3: Ridge regression

Logic ▾

为了求解 Lasso estimator, 可以将 Lasso 的 objective function 改写为

$$\min_{\vec{b}} \left\| Y - X\vec{b} \right\|_2^2 + \lambda \left\| \vec{b} \right\|_1 = \min_{\vec{b}} (Y - X\vec{b})^\top (Y - X\vec{b}) + \lambda \sum_{i=1}^p |b_i|$$

一种求解思路是使用 First Order Condition, 但问题在于 $\sum_{i=1}^p |b_i|$ 为 non-differentiable

因此 $\hat{\beta}_{\text{Lasso}}^{(\lambda)}$ 没有 closed form, 我们需要使用 numerical methods (iterative approach)

2 Lasso 的 Computation

Logic ▾

一个求解 Lasso 的工具是 Soft-Thresholding Lemma

2.1 Soft-Thresholding Lemma (Lasso with 1 Variable)

对于 Lasso with 1 variable, 有

$$\arg \min_{b \in \mathbb{R}} \frac{1}{2} (b - b_0)^2 + \lambda |b| = \begin{cases} b_0 - \lambda & \text{if } b_0 \geq \lambda \\ 0 & \text{if } b_0 \in (-\lambda, \lambda) \\ b_0 + \lambda & \text{if } b_0 \leq -\lambda \end{cases}$$

$$\lambda = 2$$




FIGURE 15.4: Soft-thresholding

2.2 Coordinate Descent for Lasso

Settings:

X 和 Y 为 standardized

Goal:

求解

$$\min_{b_1, \dots, b_p} \frac{1}{2n} \sum_{i=1}^n (y_i - b_1 x_{i1} - \dots - b_p x_{ip})^2$$

Procedures:

Step 1:

Initialize $\hat{\beta}$ (可以使用 $\hat{\beta}_{\text{OLS}}$)

Step 2:

对于 $j = 1, \dots, p$, 依次按照以下方式更新 $\hat{\beta}_j$ (令 $\hat{\beta}_1, \dots, \hat{\beta}_{j-1}, \hat{\beta}_{j+1}, \dots, \hat{\beta}_p$ fixed):

- 定义 partial residual (不包括 b_j 的 residual):

$$r_{ij} = y_i - \sum_{k \neq j} b_k x_{ik}$$

- 将 objective function 改写为:

$$\arg \min_{b_j \in \mathbb{R}} \frac{1}{2n} \sum_{i=1}^n (r_{ij} - b_j x_{ij})^2 + \lambda \sum_{i=1}^p |b_j|$$

- 求解 simple regression $r_{ij} \sim x_{ij}$, 得到:

$$\hat{\beta}_{j,0} = \frac{\frac{1}{n} \sum_{i=1}^n x_{ij} r_{ij}}{\frac{1}{n} \sum_{i=1}^n x_{ij}^2} = \frac{1}{n} \sum_{i=1}^n x_{ij} r_{ij} \quad (\text{分母在 standardize 后为1})$$

- 可以将 objective function 进一步改写:

$$\begin{aligned} & \arg \min_{b_j \in \mathbb{R}} \frac{1}{2n} \sum_{i=1}^n (r_{ij} - b_j x_{ij})^2 + \lambda \sum_{i=1}^p |b_j| \\ \iff & \arg \min_{b_j \in \mathbb{R}} \frac{1}{2n} \sum_{i=1}^n (r_{ij} - \hat{\beta}_{j,0} x_{ij})^2 + \frac{1}{2n} \sum_{i=1}^n (\hat{\beta}_{j,0} x_{ij} - b_j x_{ij})^2 + \lambda \sum_{i=1}^p |b_j| \\ \iff & \arg \min_{b_j \in \mathbb{R}} \frac{1}{2n} (\hat{\beta}_{j,0} - b_j)^2 \sum_{i=1}^n x_{ij}^2 + \lambda \sum_{i=1}^p |b_j| \\ \iff & \arg \min_{b_j \in \mathbb{R}} \frac{1}{2} (b_j - \hat{\beta}_{j,0})^2 + \lambda \sum_{i=1}^p |b_j| \end{aligned}$$

- 使用 Soft-Thresholding Lemma 求解 $\hat{\beta}_j(\lambda)$:


$$\hat{\beta}_j = \arg \min_{b_j \in \mathbb{R}} \frac{1}{2} (b_j - \hat{\beta}_{j,0})^2 + \lambda |b_j| = \begin{cases} \hat{\beta}_{j,0} - \lambda & \text{if } \hat{\beta}_{j,0} \geq \lambda \\ 0 & \text{if } \hat{\beta}_{j,0} \in (-\lambda, \lambda) \\ \hat{\beta}_{j,0} + \lambda & \text{if } \hat{\beta}_{j,0} \leq -\lambda \end{cases}$$

Step 3:

重复以上步骤直到 convergence

2.3 对多个 λ 拟合模型

在 R 中, 可以使用 `glmnet` 同时对多个 λ fit models (Ridge / Lasso)



Logic ▾

对于 Lasso regression, 其有以下缺点:

- 至多选取 n 个 predictors
- 没有 group effect (当一组 predictors 高度相关时, Lasso 可能只会随机从中选取一个)
- 当 predictors 存在高度共线性时, Lasso 的表现不如 Ridge

因此, 我们考虑结合 Lasso 和 Ridge

| 3 Elastic Net

| 3.1 Elastic Net 的 Objective Function

Elastic Net 的 objective function 为

$$\text{RSS}(b_j) + \lambda \sum_{j=1}^p (\alpha b_j^2 + (1 - \alpha) |b_j|)$$

其中 $\alpha \in [0, 1]$

⚠ Remark: α 和 λ 的选取 ▾

Elastic Net 需要选取 α 和 λ , 可以通过构建 2-dimensional grid, 并同时 α 和 λ minimize cross-validation error 实现选取

⚠ Remark: Elastic Net 的优势 ▾

- 类似于 Lasso, 倾向于选取 sparse solutions
- 类似于 Ridge, 能够处理高度共线性的 predictors