

STAT230A Lecture 25 Transformation of the Outcome

Logic ▾

很多时候数据不会呈线性分布 (可能沿曲线分布, 如 quadratic), 若此时我们仍然使用 linear regression, 则 $\mathbb{E}[\varepsilon_i | X] = 0$ 的条件通常不满足

此时, 我们希望对 y (或 X) 进行 transformation, 使模型更好地 fit 数据

在本节 lecture 中, 我们主要讨论对 outcome y 进行 transformation 的方法

1 对 Outcome 进行 Transformation

1.1 $\log(y) \sim X$ Model

一种常见的思路是对 outcome y 进行 log transformation, 即

$$y_i \rightarrow \log y_i$$

从而使数据更接近 linear

⚠ Remark: $y \leq 0$ 时的 Transformation ▾

若存在某个 $y \leq 0$, 则采用以下 transformation

$$y_i \rightarrow \log(y_i + M)$$

其中 M 为一个 big enough number

⚠ Remark ▾

当 Y 关于 X convex 时, log transformation 能很好地压缩较为分散的 Y_i 's, 但当 Y 关于 X concave 时, log transformation 反而可能会使较为分散的 Y_i 's 更分散, 此时可以考虑使用 exponential transformation

1.2 $\log(y) \sim X$ Model 的 Coefficient Interpretation

Settings:

考虑以下 settings:

- y 表示 wages
- x 表示 years of education

对 linear regression 的 interpretation:

考虑 linear model $y_i = \alpha + x_i\beta + \varepsilon$, 即 fitted model 为 $\hat{y}_i = \hat{\alpha} + x_i\hat{\beta}$

令 i 和 j 为两个 individuals, with $x_j = x_i + 1$, 则

$$\hat{y}_j - \hat{y}_i = \hat{\beta}$$

因此 $\hat{\beta}$ 为 average amount by which y (wages) are higher for (otherwise identical 其他变量相同) individuals with 1 extra x (year of education)

对 $\log(y) \sim X$ model 的 interpretation:

考虑对 y 进行 log-transformation, 即 fitted model 为 $\log(\hat{y}) = \hat{\alpha} + x\hat{\beta}$

令 i 和 j 为两个 individuals, with $x_j = x_i + 1$, 则

$$\begin{aligned}\log \hat{y}_j - \log \hat{y}_i &= \hat{\beta} \\ \Rightarrow \log \left(\frac{\hat{y}_j}{\hat{y}_i} \right) &= \hat{\beta} \\ \Rightarrow \frac{\hat{y}_j}{\hat{y}_i} &= \exp(\hat{\beta})\end{aligned}$$

因此 $\exp(\hat{\beta})$ 为 multiplicative factor by which y (wages) are higher for (otherwise identical) individuals with 1 extra x (year of education), 即

$$X + 1 \Rightarrow \exp(\hat{\beta}) \cdot Y$$

⚠ **Remark:** $\hat{\beta}$ 较小时, 可直接用 $\hat{\beta}$ 近似增加比例 ∨

当 w 较小时, 有 $\log(1 + w) \approx w$, 因此当 $\hat{\beta}$ 较小时, 有

$$\begin{aligned}\log(1 + \hat{\beta}) &\approx \hat{\beta} \\ \Rightarrow 1 + \hat{\beta} &\approx \exp(\hat{\beta}) \\ \Rightarrow \exp(\hat{\beta}) - 1 &\approx \hat{\beta}\end{aligned}$$

因此

$$\frac{\hat{y}_j - \hat{y}_i}{\hat{y}_i} = \exp(\hat{\beta}) - 1 \approx \hat{\beta}$$

即

$$1 \text{ unit increase in } X \xrightarrow{\text{approx.}} \hat{\beta} \cdot 100\% \text{ increase in } Y$$

≡ **Example** ∨

若 $\log(\hat{y}_i) = \hat{\alpha} + \hat{\beta}x_i$ and $\hat{\beta} = 0.2$, 则对于 individuals with 1 extra year of education

- 其 wage 为 $\exp(0.2) \approx 1.22$ times higher
- 其 wage 大约增加了 $\exp(\hat{\beta}) - 1 \approx \hat{\beta} = 0.2$ 的比例

🔄 **Logic** ∨

有时我们也对 X 进行 log-transformation

1.3 $\log(y) \sim \log(X)$ Model 的 Coefficient Interpretation

Settings:

考虑以下 settings:

- y 表示 wages
- x 表示 past wages

对 $\log(y) \sim \log(X)$ model 的 interpretation:

若我们对 X 也进行 log-transformation, 则

$$\begin{aligned}\log(\hat{Y}_i) &= \hat{\alpha} + \hat{\beta} \log(X_i) \\ \Rightarrow \hat{Y}_i &= \exp(\hat{\alpha}) \cdot \exp\{\hat{\beta} \log(X_i)\} \\ \Rightarrow \hat{Y}_i &= \exp(\hat{\alpha}) \cdot X_i^{\hat{\beta}}\end{aligned}$$

令 i 和 j 为两个 individuals, with $x_j = ax_i$, 即 $\text{past wages}_i = a \cdot \text{past wages}_j$, 则

$$\frac{\text{wages}_i}{\text{wages}_j} = a^{\hat{\beta}}$$

因此 $a^{\hat{\beta}}$ 为 multiplicative factor by which y (wages) are higher for (otherwise identical) individuals with a times increase in x (past wages), 即

$$a \cdot X \Rightarrow a^{\hat{\beta}} \cdot Y$$

⚠ Remark

考虑与 $\log(Y) \sim X$ model 中类似的 approximation,

$$\begin{aligned} \frac{\text{wages}_i}{\text{wages}_j} &= a^{\hat{\beta}} \\ \Rightarrow \frac{\text{wages}_i}{\text{wages}_j} &\approx 1 + \hat{\beta}(a - 1) \\ \Rightarrow \frac{\text{wages}_i - \text{wages}_j}{\text{wages}_j} &\approx \hat{\beta}(a - 1) \\ \Rightarrow \frac{\text{wages}_i - \text{wages}_j}{\text{wages}_j} &\approx \hat{\beta} \cdot 0.01 \quad (\text{取 } a = 1.01) \end{aligned}$$

则 $\hat{\beta}$ 约等于 percentage increase in Y we expect to be associate with a 1% increase in X , 即

$$1\% \text{ increase in } X \xrightarrow{\text{approx.}} \hat{\beta} \% \text{ increase in } Y$$


💡 Logic

很多时候 log-transformation 并不起作用, 此时可以考虑 Box-Cox transformation

1.4 Box-Cox Transformation

定义 Box-Cox transformation 为

$$y \rightarrow g_{\lambda}(y) = \begin{cases} \log y & \text{if } \lambda = 0 \\ \frac{y^{\lambda} - 1}{\lambda} & \text{if } \lambda \neq 0 \end{cases}$$



⚠ Remark: Box-Cox Transformation 在 $\lambda = 0$ 时的取值

注意到

$$\lim_{\lambda \rightarrow 0} \frac{y^{\lambda} - 1}{\lambda} = \log y$$

因此当 $\lambda = 0$ 时取 $g_\lambda(y) = \log y$ 是一个 natural choice

⚠ Remark: λ 的选取 ∨

使用 Box-Cox transformation 需要选取 λ 的值, 主要有以下方法:

- 使用 maximum likelihood (见 textbook)
- 尝试多个 λ 的值并选取最好的一个
- 直接使用 $y \rightarrow y^2$ 或 $y \rightarrow \sqrt{y}$

| 1.5 Detecting Need for Transformation

一种检查是否需要 transformation 的方法是作出 $\hat{\varepsilon}$ 关于 $\hat{y}$ 的图

若 $\hat{\varepsilon}$ 关于 $\hat{y}$ 呈现曲线状分布/逐渐发散型分布, 则可以考虑对 y 进行 transformation