

STAT230A Lecture 26 Transformation of the Predictor

Logic ▾

对于更复杂的数据 (y 关于 x 的分布为 non-linear 且较复杂), 对 y 进行 transformation 往往不足以解决问题, 一种解决方法是对 x 进行 transformation, 即 model y as a polynomial function of x

1 对 Predictor 进行 Transformation

Logic ▾

首先考虑 single x 的情况, 此时可以非常轻易地写出 polynomial regression 的形式

1.1 Polynomial Regression

考虑以下 polynomial regression:

$$y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + \beta_3 x_i^3 + \cdots + \beta_p x_i^p + \varepsilon_i$$

即

$$\underbrace{\begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix}}_Y \approx \underbrace{\begin{bmatrix} 1 & x_1 & x_1^2 & \cdots & x_1^p \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_n & x_n^2 & \cdots & x_n^p \end{bmatrix}}_X \underbrace{\begin{bmatrix} \hat{\beta}_0 \\ \vdots \\ \hat{\beta}_p \end{bmatrix}}_{\hat{\beta}}$$

则仍可以使用 OLS estimator 求解 $\hat{\beta}$:

$$\hat{\beta} = (X^\top X)^{-1} X^\top Y$$

⚠ Remark: Polynomial Regression 的 Interpretation ▾

需要注意的是, polynomial regression 的 interpretation 较为困难, 考虑单个 β_i 并不是非常有用, 此时通常通过作出 $\hat{y}$ 关于 x 的图像来替代 interpretation

⚠ Remark: Overfitting ▾

当 p 较大时, polynomial regression 很可能 overfitting, 因此通常需要辅以 cross-validation 或其他 model selection techniques

Logic ▾

接下来考虑 multiple regression 的情况, 此时仍然可以 generalize polynomial regression 的想法, 从而得到 generalized additive model

1.2 Generalized Additive Model (GAM)

考虑以下 polynomial regression for multiple x :

$$y_i = \underbrace{f(x_i)}_{\text{polynomial}} + \varepsilon_i$$

$$= \beta_0 + \sum_{j=1}^J \beta_j \underbrace{f_j(x_{ij})}_{\text{polynomial}} + \varepsilon_i$$

其中 J 为 number of predictors (除去 intercept)

即

$$\underbrace{\begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix}}_Y \approx \underbrace{\begin{bmatrix} 1 & x_{11} & x_{11}^2 & \cdots & x_{11}^{K_1} & x_{12} & x_{12}^2 & \cdots & x_{12}^{K_2} & \cdots & x_{1J} & x_{1J}^2 & \cdots & x_{1J}^{K_J} \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots & \vdots & \ddots & \vdots & \ddots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n1}^2 & \cdots & x_{n1}^{K_1} & x_{n2} & x_{n2}^2 & \cdots & x_{n2}^{K_2} & \cdots & x_{nJ} & x_{nJ}^2 & \cdots & x_{nJ}^{K_J} \end{bmatrix}}_X \underbrace{\begin{bmatrix} \hat{\beta}_0 \\ \vdots \\ \hat{\beta}_p \end{bmatrix}}_{\hat{\beta}}$$

其中 $X \in \mathbb{R}^{n \times (1 + \sum_{j=1}^J K_j)}$ (最初为 $\mathbb{R}^{n \times (J+1)}$)

此时仍可以使用 OLS estimator 求解 $\hat{\beta}$:

$$\hat{\beta} = (X^\top X)^{-1} X^\top Y$$

⚠ Remark: GAM 的优缺点 ∨

GAM 的优点:

- 可以使某些 $f_j(x_{ij})$ 较其他的更 flexible
- 可以混合 categorical variables 和 continuous variables
- 所有的 probability models (除了 F-test) 均 works

GAM 的缺点:

GAM 中的 additive 表示 x_i 的 effect 不受 x_j 的 value 影响, 因此 model 中不能有 $x_{i1} \cdot x_{i2}$ 这样的 interaction term

⚠ Remark: gam Package ∨

可以使用 `gam` package 来作出 $f(x_j)$ 关于 x_j 的图像

⚠ Remark: GAM 的 Generalization ∨

可以进一步 generalize GAM 至 Splines, 即在 GAM 的基础上再将 x-values 分为不同的区域, 对每个区域分别 fit GAM