

STAT230A Lecture 29 Weighted Least Squares (Application)

1 Weighted Least Squares 的应用

Logic ▾

我们将主要介绍 WLS 的三种应用:

- known heteroskedasticity
- aggregated data
- survey sampling

1.1 WLS 的 Application 1: Known Heteroskedasticity

Settings:

假设我们有新旧两套观测工具, 其中

- 新旧观测工具的 measure 均为 unbiased
- 旧观测工具的 measure variance 为新观测工具的 1.5 倍

此时:

- NLM: 不适用 (NLM 要求 variance 相同)
- HLM: 可以使用, 但会丢失 1.5 倍这个关键信息

WLS 的使用:

考虑使用 WLS, 令

$$\Sigma = \begin{bmatrix} 1.5 & & & & \\ & \ddots & & & \\ & & 1.5 & & \\ & & & 1 & \\ & & & & \ddots \\ & & & & & 1 \end{bmatrix}$$

此时在对 $\hat{\beta}$ 进行 estimation 或 inference 时, 旧观测工具的数据将有较低的权重 $\frac{1}{1.5} = \frac{2}{3}$

Remark ▾

若我们不知道 variance 相差 1.5 倍这个信息, 则考虑使用 HLM

1.2 WLS 的 Application 2: Aggregated Data

Settings:

考虑 aggregated data 已知, 但 individual data 未知的情况

令 group i 的 sample size 为 n_i

Example: Aggregated Data 的例子 ▾

考虑 classrooms:

- y_i 表示各个班级的 average test score
- x_i 表示各个班级的 grade level, teacher ID 等班级内部共享的 features
- n_i 表示各个班级的 number of students

考虑 voting precincts:

- y_i 表示候选人在该各个选区的 support rate
- x_i 表示各个选区的 past support rate, demographics 等选区内部共享的 features
- n_i 表示各个选区的 number of voters

WLS 的使用:

由于 WLS 的 estimation 为

$$\hat{\beta} = \arg \min_b \sum_{i=1}^n w_i (y_i - x_i^\top b)^2$$

为了对 sample size 更大的 group 给予更多 weight, 令 $w_i = n_i$, 即

$$\Sigma = \begin{bmatrix} 1/n_1 & & \\ & \ddots & \\ & & 1/n_n \end{bmatrix}$$

$$\Rightarrow y_i \sim \left(x_i^\top \beta, \frac{\sigma^2}{n_i} \right)$$

⚠ Remark: Ecological Inference ▾

通常情况下, 我们更关心 individuals 而不是 aggregates, 但对于 aggregates 的结论并不能代表关于 individuals 的结论, 此时需要考虑 ecological inference, 用 aggregate (group-level) 数据去推断 individual-level 关系

1.3 WLS 的 Application 3: Survey Sampling

Settings:

考虑以下情境:

- 共有 N 个 population data: $(x_1^*, y_1^*), \dots, (x_N^*, y_N^*)$
- 我们对其进行 sampling, 得到 $(x_1, y_1), \dots, (x_n, y_n)$

我们希望使用 sample data 推断 population data

Sampling method 的选取:

一种 sampling method 是使用 i.i.d. sampling, 但这种方法容易漏掉 rare subgroups, 因此我们希望 rare subgroups 的 data 有更高的概率被选中

令:

$$I_i = \begin{cases} 0, & \text{if not in the sample of size } n \\ 1, & \text{if in the sample of size } n \end{cases}$$

$$\pi_i^* = \mathbb{P}(I_i = 1)$$

其中 sampling probability π_i^* 可以人为指定, 确保 rare subgroups 有更高的 π_i^*

WLS 的使用:

考虑使用 sample data 对 $\hat{\beta}_N$ 进行 estimation, 其中

$$\hat{\beta}_N = \left(\sum_{i=1}^N (x_i^*) (x_i^*)^\top \right)^{-1} \sum_{i=1}^N x_i^* y_i^*$$

注意到

$$\sum_{i=1}^N (x_i^*)(x_i^*)^\top = \mathbb{E} \left[\sum_{i=1}^N \frac{I_i}{\pi_i^*} (x_i^*)(x_i^*)^\top \right] = \mathbb{E} \left[\sum_{i=1}^n \frac{x_i x_i^\top}{\pi_i} \right]$$

$$\sum_{i=1}^N x_i^* y_i^* = \mathbb{E} \left[\sum_{i=1}^N \frac{I_i}{\pi_i^*} x_i^* y_i^* \right] = \mathbb{E} \left[\sum_{i=1}^n \frac{x_i y_i}{\pi_i} \right]$$

因此 $\hat{\beta}_N$ 的一种 estimation 为:

$$\hat{\beta}_n = \left(\sum_{i=1}^n \frac{x_i x_i^\top}{\pi_i} \right)^{-1} \cdot \left(\sum_{i=1}^n \frac{x_i y_i}{\pi_i} \right)$$

即 WLS with weight $w_i = \frac{1}{\pi_i}$

⚠ **Remark: 与 Causal Inference 的联系** ▾

该方法可以与 causal inference 中的 inverse probability weighting 联系起来

⚠ **Remark: Survey Weight** ▾

survey weight $\frac{1}{\pi_i}$ 通常会作为单独的一列随数据给出