

STAT230A Lecture 30 Logistic Regression (Binary Outcomes)

1 Logistic Regression

Logic ▾

对于 Gauss-Markov Model 和 Normal Linear Model:

$$Y = X\beta + \varepsilon \quad \varepsilon \sim \mathcal{N}(0, \sigma^2 I)$$

其优势在于:

- Interpretability: β_j 表示 difference in expected value of y_i associated with 1-unit change in x_i
- Closed-form estimation: $\hat{\beta} = (X^\top X)^{-1} X^\top Y$
- Optimality: $\hat{\beta}$ 为 BLUE under G-M / MLE under NLM

但问题在于, 上述模型均假设 y 在 $\mathbb{R}$ 上取值, 而事实上 y 的取值通常为 restricted (binary / categorical / non-negative integer), 此时需要使用 generalized linear model

1.1 OLS 在处理 Binary Response 时的问题

对于 binary y , linear probability model (OLS) $\hat{\beta} = (X^\top X)^{-1} X^\top Y$ 仍然可行

但 OLS 存在以下问题:

- 可能出现 $\hat{y}_i > 1$ 或 $\hat{y}_i < 0$ 的情况: 难以将 $\mathbb{E}[\hat{y}_i | x_i]$ interpret 为 probability
- 难以 interpret β_j : 若使用之前的 interpretation (将 $\mathbb{E}[\hat{y}_i | x_i]$ 视作 probability), 则 β_j 的增加或减小可能导致 $\mathbb{E}[\hat{y}_i | x_i]$ 大于 1 或小于 0
- $\hat{\beta}_i$ 不再是 MLE: NLM 不再成立

Remark ▾

当 $\mathbb{E}[y_i | x_i]$ 远离 0 或 1 的时候, 可以考虑使用 linear probability model

Logic ▾

为了解决上述问题, 考虑令 $\mathbb{P}(y_i | x_i) = g(x_i^\top \beta)$, 其中 $g(\cdot)$ 为 nonlinear function, 其被称为 inverse link function

1.2 Logistic Regression

令:

$$\mathbb{P}(y_i | x_i) = g(x_i^\top \beta)$$

其中 $g(\cdot)$ 有两种常见的选择:

- Normal cdf: $g = \Phi(x_i^\top \beta)$, 此时将得到 **probit regression**
- Logistic cdf: $g = \frac{\exp(x_i^\top \beta)}{1 + \exp(x_i^\top \beta)}$, 此时将得到 **logistic regression**

Remark: 对 Link Function $g(\cdot)$ 的理解 ▾

令 $y_i \in \{0, 1\}$ 由某个 hidden continuous value u_i 决定:

$$y_i = \mathbf{1}\{x_i^\top \beta - u_i > 0\}$$

则有

$$\begin{aligned}\mathbb{P}(y_i = 1 \mid x_i) &= \mathbb{E}[\mathbf{1}\{x_i^\top \beta - u_i > 0\}] \\ &= \mathbb{P}(x_i^\top \beta > u_i) \\ &= \mathbb{P}(u_i < x_i^\top \beta) \\ &= F_u(x_i^\top \beta)\end{aligned}$$

由于 $\mathbb{P}(y_i \mid x_i) = g(x_i^\top \beta)$, 因此 $g(\cdot)$ 可以理解为 hidden variable u 的 cdf

Logic ▾

我们通常选则 $g(\cdot)$ 为 logistic cdf, 即 logistic regression, 相较于其他 link function, 其优势在于 interpretation

1.3 Logistic Regression 的 Interpretation

Inverse link function:

对于 logistic regression, 对 $g(\cdot)$ 进行 inverse, 则有

$$\begin{aligned}\mathbb{P}(y_i = 1 \mid x_i) &= g(x_i^\top \beta) \\ \Rightarrow \text{logit}(\mathbb{P}(y_i = 1 \mid x_i)) &= x_i^\top \beta\end{aligned}$$

其中 $\text{logit}(z) = \log\left(\frac{z}{1-z}\right)$, $z \in (0, 1)$

Odds ratio interpretation:

对于 probability p , 我们称 $\frac{p}{1-p}$ 为 **odds**, 对于 logistic regression, 有

$$\underbrace{\log\left(\frac{\mathbb{P}(y_i = 1 \mid x_i)}{1 - \mathbb{P}(y_i = 1 \mid x_i)}\right)}_{\text{conditional odds}} = x_i^\top \beta$$

考虑 1 unit increase in x_{ij} , 则有

$$\begin{aligned}\beta_j &= \log(\text{conditional odds} \mid x_{ij+1}) - \log(\text{conditional odds} \mid x_{ij}) \\ &= \log\left(\underbrace{\frac{\text{odds}(y_i = 1 \mid x_{i1}, \dots, x_{ij} + 1, \dots, x_{ip})}{\text{odds}(y_i = 1 \mid x_{i1}, \dots, x_{ij}, \dots, x_{ip})}}_{\text{odds ratio (OR) for } x_j}\right)\end{aligned}$$

因此 $\exp(\beta_j) = \text{odds ratio for } x_j$

Example ▾

考虑以下情境:

- y 表示 purchase decision
- x 表示 age
- $\beta_j = 0.2$

此时 $\exp(0.2)$ 表示 fraction by which odds of purchase are higher for people 1 year older

事实上, 若 $\beta_j > 0$, 则 $\exp(\beta_j) > 1$, 因此 odds ratio > 1

1.4 Logistic Regression 的 Estimation

Logic ▾

Logistic regression 可以写作以下 parametric model

$$\begin{cases} y_i | \pi_i \sim \text{Bernoulli}(\pi(x_i, \beta)) \\ \pi(x_i, \beta) = g(x_i^\top \beta) = \frac{\exp(x_i^\top \beta)}{1 + \exp(x_i^\top \beta)} \end{cases}$$

此时可以考虑使用 maximum likelihood estimation 进行 estimation

Likelihood:

Logistic regression 的 likelihood function 为

$$\begin{aligned} L(\beta) &= \prod_{i=1}^n f(y_i | x_i, \beta) \\ &= \prod_{i=1}^n [\pi(x_i, \beta)]^{y_i} [1 - \pi(x_i, \beta)]^{1-y_i} \\ &= \prod_{i=1}^n \underbrace{\left(\frac{\pi(x_i, \beta)}{1 - \pi(x_i, \beta)} \right)^{y_i}}_{\text{odds}} [1 - \pi(x_i, \beta)] \end{aligned}$$

代入 $\pi(x_i^\top \beta) = \frac{\exp(x_i^\top \beta)}{1 + \exp(x_i^\top \beta)}$, 有

$$\begin{aligned} L(\beta) &= \prod_{i=1}^n \left[e^{x_i^\top \beta} \right]^{y_i} \left(\frac{1}{1 + \exp(x_i^\top \beta)} \right) \\ &= \prod_{i=1}^n \frac{e^{y_i x_i^\top \beta}}{1 + e^{x_i^\top \beta}} \end{aligned}$$

因此 log-likelihood 为

$$l(\beta) = \sum_{i=1}^n \left[y_i x_i^\top \beta - \log(1 + e^{x_i^\top \beta}) \right]$$

对其求导, 有

$$\begin{aligned} \frac{\partial l(\beta)}{\partial \beta} &= \sum_{i=1}^n \left(x_i y_i - \frac{1}{1 + e^{x_i^\top \beta}} \cdot e^{x_i^\top \beta} \cdot x_i \right) \\ &= \sum_{i=1}^n x_i \left(y_i - \frac{e^{x_i^\top \beta}}{1 + e^{x_i^\top \beta}} \right) \\ &= \sum_{i=1}^n x_i (y_i - \pi(x_i, \beta)) \end{aligned}$$

令上式等于 0, 即可求解 β 的 MLE

⚠ Remark: 和 OLS 的联系 ∨

对于 OLS, 其 normal equation 为

$$\sum_{i=1}^n x_i (y_i - x_i^\top \beta) = 0$$

Logistic regression 在此基础上加入了 link function $\pi(\cdot)$

⚠ Remark: X 包含 Intercept 时的特殊性质 ∨

对于 $\hat{\beta}_{\text{MLE}}$, 其满足:

$$\sum_{i=1}^n x_i (y_i - \pi(x_i, \hat{\beta}_{\text{MLE}})) = 0$$

类似于 OLS, 若 X 包含 intercept column, 则 residual 之和为 0:

$$\sum_{i=1}^n \underbrace{(y_i - \pi(x_i, \hat{\beta}_{\text{MLE}}))}_{\text{residual}} = 0$$

即

$$\underbrace{\bar{y}}_{\text{proportion of 1's}} = \underbrace{\bar{\pi}}_{\text{avg. of fitted value}}$$

MLE 的求解:

注意到上式无法求出 closed form, 因此考虑使用 numerical methods 求解:

$$\begin{aligned} \frac{\partial l(\beta)}{\partial \beta} \Big|_{\beta=\hat{\beta}_{\text{MLE}}} &\approx \frac{\partial l(\beta)}{\partial \beta} \Big|_{\beta=\hat{\beta}_{\text{current}}} + \frac{\partial^2 l(\beta)}{\partial \beta \partial \beta^\top} \Big|_{\beta=\hat{\beta}_{\text{current}}} (\hat{\beta}_{\text{MLE}} - \hat{\beta}_{\text{current}}) = 0 \\ \Rightarrow \hat{\beta}_{\text{MLE}} &\approx \hat{\beta}_{\text{current}} - \left(\frac{\partial^2 l(\beta)}{\partial \beta \partial \beta^\top} \Big|_{\beta=\hat{\beta}_{\text{current}}} \right)^{-1} \frac{\partial l(\beta)}{\partial \beta} \Big|_{\beta=\hat{\beta}_{\text{current}}} \end{aligned}$$

其中

$$\begin{aligned} \frac{\partial l(\beta)}{\partial \beta} &= \sum_{i=1}^n x_i (y_i - \pi(x_i, \beta)) = X^\top (Y - \bar{\pi}) \\ \frac{\partial^2}{\partial \beta \partial \beta^\top} &= - \sum_{i=1}^n \pi(x_i, \beta) [1 - \pi(x_i, \beta)] x_i x_i^\top = -X^\top W X \end{aligned}$$

其中

$$\pi_i = \pi(x_i, \beta) \quad W = \begin{bmatrix} \pi_1(1 - \pi_1) & & \\ & \ddots & \\ & & \pi_n(1 - \pi_n) \end{bmatrix}$$

因此重复以下步骤直到收敛:

$$\hat{\beta}_{\text{new}} = \hat{\beta}_{\text{old}} + [X^\top \hat{W}_{\text{old}} X]^{-1} X^\top (Y - \hat{\pi}_{\text{old}})$$

⚠ Remark: Iterative Reweighted Least Squares (IRLS) ▾

将上式写作 weighted least squares 的形式, 即可得到 iterative reweighted least squares (IRLS)

🔗 Logic ▾

可以使用 MLE 的 asymptotic distribution 对 Logistic regression 进行 inference

1.5 Logistic Regression 的 Inference

Asymptotic distribution:

对于 MLE, 有

$$\hat{\beta}_{\text{MLE}} \xrightarrow{d} \mathcal{N}(\beta, \hat{I}_n(\beta)^{-1})$$

其中

$$\hat{I}_n(\beta)^{-1} = (X^\top \hat{W} X)^{-1}$$

Hypothesis testing:

- 若 $H_0: \beta_j = 0$, 则可以使用 z-test, 将 $\hat{\beta}_j$ 与 normal distribution $\mathcal{N}(0, j^{\text{th}} \text{ diag. of } (X^\top \hat{W} X)^{-1})$ 进行比较
- 若 $H_0: \beta_1 = \dots = \beta_k = 0$, 则可以使用 F-type statistics, 并将其与 χ^2 distribution (不是 F distribution) 进行比较

⚠ Remark: 其他形式的 Hypothesis Testing ▾

也可以选用其他形式的 hypothesis testing, 如

- Wald test
- Likelihood ratio test (anova 的默认方法)

- Score test

Logic ▾

若给定 new data $\vec{x}_{n+1} = \begin{bmatrix} 1 & x_1^{(n+1)} & \dots & x_p^{(n+1)} \end{bmatrix}^\top$, 我们常常希望预测 $y_{n+1} \in \{0, 1\}$

1.6 Logistic Regression 的 Prediction

对于 new data $\vec{x}_{n+1} = \begin{bmatrix} 1 & x_1^{(n+1)} & \dots & x_p^{(n+1)} \end{bmatrix}^\top$, 可以计算

$$\pi(\vec{x}_{n+1}, \hat{\beta}) = \frac{e^{x_{n+1}^\top \hat{\beta}}}{1 + e^{x_{n+1}^\top \hat{\beta}}} \in (0, 1)$$

并进行 binarize:

$$\hat{y}_{n+1} = \mathbf{1}(\hat{\pi}_{n+1} \geq c)$$

其中 c 的选取方法包括:

- 默认情况下选取 $c = \frac{1}{2}$
- 根据 AUC curve 进行选取 (summarize performance of a prediction model across all values of c)

⚠ Remark: R 中的 Prediction ▾

在 R 中, 若使用 `glm()` function 进行 model fitting, 则可以使用 `predict(model, type="response")` 求解 $\hat{\pi}(x_i)$, 若不指定 `type`, 则默认返回 $x_i^\top \hat{\beta}$

1.7 Logistic Regression 的 Model Selection

当 p 接近 n 时, 使用以下方法进行 model selection:

- **AIC / BIC**: 基于 negative log-likelihood 而不是 RSS
- **Lasso / Ridge**: 对 negative log-likelihood 而不是 RSS 添加 regularization:

$$\arg \min_{\beta} -\frac{1}{n} \sum_{i=1}^n l_i(\beta) + \lambda \sum_{j=1}^p \beta_j^2$$

⚠ Remark: R 中的 Model Selection ▾

在 R 中, 可以使用 `glmnet` 进行 logistic regression 的 model selection