

STAT230A Lecture 31 Logistic Regression (Categorical Outcomes)

Logic ▾

很多情况下 y 为 categorical 而非 binary, 且可以进一步细分为以下两种情况:

- Nominal: 类别之间没有顺序关系, 如 (apple, banana, cherry) 或 (drive, BART, Uber)
- Ordinal: 类别之间有顺序关系, 如 (terrible, normal, good)

此时仍然可以使用 logit models

我们首先考虑 Nominal case, 此时可以使用 Multinomial Regression

1 Multinomial Regression (Nominal Outcomes)

1.1 Multinomial Regression (Naive Version)

令:

- Observed data $(x_i, y_i)_{i=1}^n$ 为 nominal
- $x_i \in \mathbb{R}^p$
- $y_i \in [1, \dots, K]$

则可以使用以下 multinomial distribution 对数据进行建模:

$$\mathbb{P}(y_i = k \mid x_i) = \pi_{ki}, \quad \text{for } i = 1, \dots, n, \quad k = 1, \dots, K$$

其中

$$\pi_{ki} = \frac{\exp(x_i^\top \beta_k)}{\sum_{l=1}^K \exp(x_i^\top \beta_l)}$$

其满足 $\sum_{k=1}^K \pi_{ki} = 1, \forall i = 1, \dots, n$

Logic ▾

Naive version 的一个问题在于 unidentifiable:

$$\begin{aligned} \pi_k(x_i) &= \frac{\exp(x_i^\top \beta_k)}{\sum_{l=1}^K \exp(x_i^\top \beta_l)} \\ &= \frac{\exp(x_i^\top \beta_k)}{\sum_{l=1}^K \exp(x_i^\top \beta_l)} \cdot \frac{\exp(x_i^\top \gamma)}{\exp(x_i^\top \gamma)} \\ &= \frac{\exp[x_i^\top (\beta_k + \gamma)]}{\sum_{l=1}^K \exp[x_i^\top (\beta_l + \gamma)]} \\ &= \frac{\exp(x_i^\top \tilde{\beta}_k)}{\sum_{l=1}^K \exp(x_i^\top \tilde{\beta}_l)} \quad (\tilde{\beta}_l := \beta_l + \gamma) \end{aligned}$$

因此 β 的选择不唯一

一种解决方法是仅使用 $\beta_1, \dots, \beta_{K-1}$, 即令 category K 为 reference level

1.2 Multinomial Regression

对于 multinomial regression, 令 category K 为 reference level, 则

$$\mathbb{P}(y_i = k \mid x_i) = \pi_k(x_i), \quad \text{for } i = 1, \dots, n, \quad k = 1, \dots, K$$

其中

$$\begin{aligned} \pi_K(x_i) &= 1 - \sum_{l=1}^{K-1} \pi_l(x_i) && \forall x_i \\ \pi_k(x_i) &= \frac{\exp(x_i^\top \beta_k)}{1 + \sum_{l=1}^{K-1} \exp(x_i^\top \beta_l)} && \forall x_i, \forall k < K \end{aligned}$$

其中 $\vec{\beta} \in \mathbb{R}^{p \times (K-1)}$

⚠ **Remark: 对 $\pi_k(x_i)$ 的理解** ✓

$\pi_k(x_i)$ 分母上的 1 可以理解为令 β_K 为 0

⚠ **Remark: Reference Category 的选取** ✓

通常选取 baseline value / most common value / default value 作为 reference category

1.3 Multinomial Regression 的 Interpretation

类似于 logistic regression, 对 link function 进行 transformation, 有

$$\beta_{kj} = \log \underbrace{\left[\frac{\pi_k(\vec{x}_i + \vec{e}_j)}{\pi_K(\vec{x}_i + \vec{e}_j)} \middle/ \frac{\pi_k(\vec{x}_i)}{\pi_K(\vec{x}_i)} \right]}_{\text{conditional log odds ratio}}$$

因此 $\exp(\beta_{kj}) = \text{conditional odds ratio for } x_j \text{ (conditional 表示限定我们在 category } k \text{ 和 reference category } K \text{ 中二选一)}$

≡ **Example** ✓

考虑以下情境:

- y 表示 decision
- x 表示 age
- reference category K 表示 driving
- $\beta_{(\text{Uber})(\text{age})} = 0.8$

则 people 1 year older have odds of taking Uber (relative to driving) $\exp(0.8)$ times higher than people 1 year younger

🔄 **Logic** ✓

类似于 logistic regression, 可以使用 MLE 对 multinomial regression 进行 estimation

1.4 Multinomial Regression 的 Estimation

Multinomial regression 的 likelihood function 为

$$L(\beta) = \prod_{i=1}^n \mathbb{P}(y_i \mid x_i) = \prod_{i=1}^n \prod_{l=1}^K [\pi_l(x_i)]^{\mathbf{1}\{y_i=l\}}$$

因此 log-likelihood function 为

$$\log L(\beta) = \sum_{i=1}^n \sum_{l=1}^K \mathbf{1}\{y_i = l\} \left[x_i^\top \beta_l - \log \sum_{l=1}^K \exp(x_i^\top \beta_l) \right]$$

因此 First-order condition, 即 (nonlinear) normal equation 为

$$\sum_{i=1}^n \sum_{l=1}^K [\mathbf{1}\{y_i = l\} - \pi_l(x_i^\top \beta_l)] x_i = 0$$

使用 Newton's method 即可求解 $\hat{\beta}_l$

⚠ Remark ▾

在 R 中, multinomial regression 的相关 function 不在 `glm` 包中, 而是在 `nnet` 中, 可以使用 `multinom(y~x)` 进行 multinomial regression

🔄 Logic ▾

类似于 logistic regression, 可以使用 MLE theory 对 multinomial regression 进行 inference

1.5 Multinomial Regression 的 Inference

对于 MLE, 有

$$\hat{\beta}_{lj} \xrightarrow{d} \mathcal{N}(\beta_{lj}, \hat{I}_n(\beta_{lj})^{-1})$$

其中 $\hat{I}_n(\beta_{lj})^{-1}$ 为关于 $\hat{\pi}_l(x_i)$ 的 function, 由此可以使用 z-test / F-test 进行 hypothesis testing

对于 ordinal outcomes, 我们可以使用 proportional odds model, 通过引入 latent variable 来对次序建模 (其可被视作 OLS 与 multinomial regression 的结合)

2 Proportional Odds Model (Ordinal Outcomes)

2.1 Proportional Odds Model

令:

- $y_i \in \{1, 2, \dots, K\}$ 表示 ordinal category
- $y_i^* = x_i^\top \beta + \varepsilon_i$ 表示 latent variable, 其中 $\varepsilon_i \sim g(\cdot)$
- $\alpha_1, \dots, \alpha_{K-1}$ 表示 thresholds

考虑以下 setting:

$$y_i = \begin{cases} 1 & \text{if } y_i^* \leq \alpha_1 \\ k & \text{if } \alpha_{k-1} < y_i^* \leq \alpha_k \\ K & \text{if } y_i^* > \alpha_{K-1} \end{cases}$$

则 proportional odds model 为

$$\begin{aligned} \mathbb{P}(y_i = k | x_i) &= \mathbb{P}(y_i \leq k | x_i) - \mathbb{P}(y_i \leq k-1 | x_i) \\ &= \mathbb{P}(x_i^\top \beta + \varepsilon_i \leq \alpha_k | x_i) - \mathbb{P}(x_i^\top \beta + \varepsilon_i \leq \alpha_{k-1} | x_i) \\ &= g(\alpha_k - x_i^\top \beta) - g(\alpha_{k-1} - x_i^\top \beta) \end{aligned}$$

若 g 为 logistic function, 则有

$$P(y_i \leq k | x_i) = \frac{\exp(\alpha_k - x_i^\top \beta)}{1 + \exp(\alpha_k - x_i^\top \beta)}$$

⚠ Remark: Proportional Odds Model 和 Multinomial Regression 的关系 ▾

相较于对 $y = k$ 进行 modeling, proportional odds model 对 $y \leq k$ 进行 modeling, 其区别主要在于 parameters 的数量:

- Proportional odds model: non-intercepts: $\beta \in \mathbb{R}^{p-1}$ + intercepts $(\alpha_1, \dots, \alpha_{K-1})$
- Multinomial logit model: $K - 1$ 个 parameter vectors: $\beta_l \in \mathbb{R}^p$

虽然 proportional odds model 的 parameters 数更少, 但其代价在于 β 不随 category 而变化

可以通过 hypothesis testing 进行选择 (proportional odds model 为 multinomial regression 的特例)