

STAT243 Lecture 9.2 Design of Simulation Studies

1 模拟研究的基本步骤 (Basic Steps of a Simulation Study)

1. 定义单次实验 (Specify an Experiment)

明确：

- 样本量 n
- 数据分布 (e.g., Normal, t, Poisson)
- 参数值 (e.g., 均值, 方差, 回归系数)
- 感兴趣的统计量 (估计量、检验统计量等)
- 数据生成机制 (DGP: Data Generating Process)

Example> ▾

生成 $n = 100$ 个 $X_i \sim N(0, 1)$, $Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$,
其中 $\varepsilon_i \sim N(0, 1)$ 。

2. 确定要变化的输入因子 (Identify Factors to Vary)

- 样本量 (n)
- 参数 (β_1, σ^2)
- 分布类型 (Normal / t / skewed)
- 相关结构 (independent vs correlated)
每种组合形成一个 **scenario (情景)**。

3. 编写实验函数 (Write Simulation Code)

- 该函数接收上述输入参数；
- 返回感兴趣的统计量 (如估计偏差、方差等)。

```
Python
1 def simulate_once(n, beta, dist='normal'):
2     X = np.random.normal(size=n)
3     if dist == 't':
4         eps = np.random.standard_t(df=3, size=n)
5     else:
6         eps = np.random.normal(size=n)
7     Y = beta * X + eps
8     est = np.sum(X * Y) / np.sum(X**2)
9     return est
```

4. 重复实验 (Repeat the Experiment m Times)

- 对每个 scenario 重复模拟 m 次。
- 这可高度并行化 (并行于 scenario 与 replicate 两个维度)。

```
Python
1 results = [simulate_once(100, 1.0) for _ in range(1000)]
```

5. 总结与不确定性量化 (Summarize Results & Quantify Uncertainty)

- 计算均值、标准差、偏差、MSE 等；
- 模拟标准误差：

$$SE_{sim} = \frac{s}{\sqrt{m}}$$

- 若 SE_{sim} 远小于效应量，可忽略模拟误差。

6. 可视化与报告 (Visualization and Reporting)

- 表格呈现 bias、RMSE、coverage；
- 图形化呈现 (箱线图、误差条、曲线对比)。

2 各种重要考量 (Design Considerations)

1. 效率与可重现性

- 代码应结构化、模块化；
- 记录随机种子以确保可复现。

2. 与真实数据相似的结构

- 模拟分布、参数、依赖性应与目标问题相符；
- 可引入异常值、随机效应等以测试鲁棒性。

3. 控制随机变异 (Paired Designs)

- 在比较两种方法时，**使用相同的模拟数据集**，即固定随机数种子，使两方法共享相同噪声。
- 分析上可使用配对差值以降低方差。

4. 控制随机数的一致性

- 例如，在比较 t 分布与 Normal 分布数据时，可以通过相同的累积分布概率匹配：



Python

```
1 from scipy.stats import t, norm
2 import numpy as np, matplotlib.pyplot as plt
3
4 devs = np.random.normal(size=100)
5 tdevs = t.ppf(norm.cdf(devs), df=1)
6
7 plt.scatter(devs, tdevs)
8 plt.xlabel('Normal Deviates')
9 plt.ylabel('t Deviates (df=1)')
10 plt.plot([min(devs), max(devs)], [min(devs), max(devs)], color='red')
11 plt.show()
```

⚠ Remark ▾

这样可以使两组数据“成对对应”，减少随机误差的影响。

2.1 重复次数 m 的选择 (Choosing m)

- 理论上可用基本功效 (power) 计算决定 m ；
- 实践中常采用**顺序方式 (sequential)**：
 - 逐步增加 m ，直到模拟结果的精度达到可接受水平；

- 若 s/\sqrt{m} 已小于差异效应量，可停止。

3 实验设计思想在模拟中的应用 (Optional)

3.1 多因素输入的情景 (Multiple Input Variables)

- 通常需评估多个输入变量对输出结果的影响；
- 避免“一次只变一个变量”的低效方式。

3.2 全因子设计 (Full Factorial Design)

- 若输入较少，可离散化为少量水平 (levels)，进行全因子设计：
 k 个因子，每个有 L 个水平 $\rightarrow L^k$ 个情景。

Example ▾

示例：3 个输入 \times 3 个水平 $= 3^3 = 27$ 个组合。

- 适用于输入数量较少的情况。

3.3 分数因子设计 (Fractional Factorial Design)

- 当输入或水平较多时，无法执行全因子设计；
- 分数因子设计通过选择部分组合来保证：
 - 平衡性；
 - 可估计主效应与部分交互项；
 - 高阶交互项与低阶项混叠 (aliasing)。

Remark ▾

目标：在计算资源有限的前提下，最大化可解释性。

3.4 Latin Hypercube Sampling (LHS)

- 适用于输入维度很高的情况；
- 在多维输入空间内均匀采样，保证覆盖性。

步骤：

1. 假设每个输入变量 $X_j \sim U(0,1)$ ；
2. 将区间 $[0,1]$ 均分为 m 个区间；
3. 在每个区间内随机采样一个点；
4. 对每个变量独立地随机排列区间顺序；
5. 组合形成 m 个输入点。

Remark ▾

这样可在有限样本下均匀探索输入空间。
分析时关注主效应与一、二阶交互作用。

3.5 结果解释建议

- 重点放在方差分解与效应大小 (effect magnitude)，而非显著性检验；
- 在模拟研究中，“零假设成立”通常不具意义。