

STAT243 Lecture 10.2 Statistical Interpretations of Matrix Properties

1 Linear Independence, Rank, and Basis

1.1 线性无关与秩

一组向量 v_1, \dots, v_n 是线性无关的，当：

$$\sum_i c_i v_i = 0 \Rightarrow c_i = 0 \forall i$$

矩阵的 秩 (rank) = 线性无关的列 (或行) 的数量。

最大值为 $\min(\text{行数}, \text{列数})$ 。

1.2 基向量与张成空间

任意一组线性无关向量 v_i 构成的线性组合：

$$y = \sum_i c_i v_i$$

定义了该组向量张成的空间 (span)。

v_i 即为该空间的基 (basis)。

若 v_i 是正交归一化的，则：

$$c_i = \langle y, v_i \rangle = v_i^\top y$$

1.3 回归模型中的秩与空间

设计矩阵 X 的列为协变量向量：

- 若 $q = \text{rank}(X) < p$
则有 $p - q$ 列是其他列的线性组合
- 空间维数为 q , 对应 q 个基向量
- 在回归中：
 - 若 $n = p = q \rightarrow$ 唯一且精确解 (无残差)
 - 若 $n < p \rightarrow$ 欠定系统 (多解)
 - 若 $n > p \rightarrow$ 过定系统 (最小二乘求近似解)

回归的几何解释：

Y 被投影到由 X 的列张成的空间上。

1.4 Invertibility, Singularity, and Positive Definiteness

1.4.1 特征分解 (Eigendecomposition)

对于可对角化矩阵：

$$A = \Gamma \Lambda \Gamma^{-1}$$

若 A 对称：

$$A = \Gamma \Lambda \Gamma^\top$$

其中：

- Γ : 特征向量矩阵
- Λ : 对角特征值矩阵
- 非零特征值数量 = 矩阵秩

1.4.2 矩阵分类与性质

性质	定义	推论
非奇异 (nonsingular)	A^{-1} 存在	秩满 (full rank)
正定 (positive definite)	$x^\top A x > 0$	所有 $\lambda_i > 0$
半正定 (positive semi-definite)	$x^\top A x \geq 0$	一部分 $\lambda_i = 0$
奇异 (singular)	不可逆	存在 $\lambda_i = 0$

若 A 为协方差矩阵 $\text{Cov}(y)$:

$$x^\top A x = \text{Var}(x^\top y) \geq 0$$

因此协方差矩阵必为半正定矩阵。

1.4.3 结论总结

代数性质	统计解释
$A \text{ p.d.} \Leftrightarrow x^\top A x > 0 \Leftrightarrow \lambda_i > 0$	协方差矩阵，方差均为正
$A \text{ p.s.d.} \Leftrightarrow x^\top A x \geq 0 \text{ 且部分 } \lambda_i = 0$	受约束协方差矩阵，部分方向方差为 0
$\lambda_i = 0$	某线性组合无方差信息（不识别）

2 Eigen-decomposition Interpretation

生成随机向量 y 的思路：

$$y = \Gamma \Lambda^{1/2} z, \quad \text{where } \text{Cov}(z) = I$$

解释：

- $\Gamma_{\cdot i}$ 为方差主方向（特征向量）
- $\sqrt{\lambda_i}$ 为对应标准差
- z_i 为该方向上的标准化系数

2.1.1 问题与解释

1. 若 $\lambda_i = 0$:

该方向上方差为零, y 在该方向无变化。

2. 若将极小 λ_i 设为 0:

去除对应的低方差分量, 相当于“平滑”或“降维”。

3. 若 $(\Lambda^{-1})_{ii}$ 很大:

对应方向方差很小 (高精度)。

若很小 \rightarrow 对应方向方差极大 (低精度)。

| 3 Generalized (Pseudo) Inverses (optional)

若 A 不可逆, 仍可定义广义逆 A^- 使:

$$AA^-A = A$$

Moore–Penrose 伪逆 (pseudo-inverse): 唯一满足附加约束的广义逆, 记为 A^+ 。

其最小化解为:

$$x = A^+b$$

即满足 $Ax = b$ 且 $|x|$ 最小。

| 3.1 由特征分解求伪逆

$$A^+ = \Gamma \Lambda^+ \Gamma^\top, \quad \Lambda_{ii}^+ = \begin{cases} 1/\lambda_i, & \lambda_i > 0 \\ 0, & \lambda_i = 0 \end{cases}$$

统计解释:

若 $\lambda_i = 0$, 对应方向无信息 (无限方差), 伪逆将该方向方差设为 0。

| 3.2 示例: AR(1) 与 AR(2) 精度矩阵

- 一阶自回归 (AR(1)) 精度矩阵:

$$(1 \ -1 \ 0 \ 0 \ 0 \ -1 \ 2 \ -1 \ 0 \ 0 \ 0 \ -1 \ 2 \ -1 \ 0 \ 0 \ 0 \ -1 \ 2 \ -1 \ 0 \ 0 \ -1 \ 1)$$

零特征值对应常数向量 (均值不可识别)。

- 二阶自回归 (AR(2)) 矩阵中有两个零特征值, 对应:

- 总和不确定性 (constant component)
- 线性趋势不确定性 (linear component)

伪逆操作即为:

将 $\lambda_i = 0$ 的分量方差设为零, 相当于约束 $\sum y_i = 0$ 或去除线性趋势。

| 4 Regression 中的 Matrices

在线性回归中:

$$\hat{\beta} = (X^\top X)^{-1} X^\top Y$$

- $X^\top X$:
 - 对称
 - 半正定 (n.n.d.)
 - 若列向量线性无关 \rightarrow 正定 (p.d.)
-

4.1.1 Hat Matrix (投影矩阵)

$$H = X(X^\top X)^{-1}X^\top$$

性质:

1. 投影: $\hat{Y} = HY$
2. 幂等性: $HH = H$
3. 奇异性: H 不可逆 (因为其秩 $< n$)
4. 唯一情况 H 可逆: $H = I$ (仅当 X 为满秩方阵且 $n = p$)

几何解释:

H 将 Y 投影到由 X 列张成的空间;

投影后再投影不改变结果, 因此 $HH = H$ 。