

STAT243 Lecture 10.5 Eigendecomposition and SVD

1 Eigendecomposition

Logic ▾

关于 Eigendecomposition 的详细论述, 见 [DDA3005 Lecture 15](#)

关于 Power method 的详细论述, 见 [DDA3005 Lecture 16](#)

关于 Inverse iteration, Rayleigh quotient iteration, QR iteration 的详细论述, 见 [DDA3005 Lecture 17](#)

关于对 QR iteration 的改进的详细论述, 见 [DDA3005 Lecture 18](#)

1.1 Eigendecomposition 的原理

- Eigendecomposition (谱分解) 在算法收敛分析、PCA 等应用中非常重要
 - 将方差结构分解为一组正交方向 (eigenvectors) 与对应的变异量 (eigenvalues)
- 对实对称矩阵 A :

$$A = \Gamma \Lambda \Gamma^\top$$

- Γ : 正交矩阵 (列为特征向量)
- Λ : 对角矩阵 (特征值, 按降序排列)
- 经典定义:

$$Ax = \lambda x$$

- 逆与平方根:

$$A^{-1} = \Gamma \Lambda^{-1} \Gamma^\top, \quad A^{1/2} = \Gamma \Lambda^{1/2}$$

- Spectral radius:

$$\rho(A) = \max |\lambda_i|$$

对于对称矩阵, spectral radius 即为 L2 norm:

$$\rho(A) = \|A\|_2$$

会在许多迭代算法的 convergence rate 中出现

1.2 Eigendecomposition 的 Computation

- 常用方法: QR algorithm
 - 第一步: 将 A 化为 upper Hessenberg (对称矩阵化为 tridiagonal)
 - 通过 Householder 或 Givens 完成初步化简
 - 之后反复做 QR 分解并 shift, 对角元素收敛到 eigenvalues
 - eigenvectors 由所有变换矩阵相乘得到
- 只需最大 (或前几个最大) 特征值时: 使用 power method
 - 通过反复乘以 A 并归一化得到最大特征向量

$$z^{(k)} = \frac{Az^{(k-1)}}{|Az^{(k-1)}|}$$

- λ_1 可通过

$$\lambda_1 \approx \frac{(Az)_i}{z_i}$$

- 找第二大 eigenvalue:
使用

$$B = A - \lambda_1 vv^\top$$

对 B 使用相同方法

1.3 Singular value decomposition

我们考虑一个 $n \times m$ 矩阵 A , 假设 $n \geq m$ 。

矩阵总能分解为

$$A = UDV^\top$$

- U : 左奇异向量, 列正交
- V : 右奇异向量, 列正交
- D : 对角矩阵, 奇异值非负
- 若 A 是方阵且对称正定, SVD 与 eigendecomposition 一致

1.3.1 Representations

- Rank- k 分解:

$$A = \sum_{j=1}^k D_{jj} u_j v_j^\top$$

每项是 rank-one 外积

- 关系:

$$A^\top A = VD^2V^\top, \quad AA^\top = UDV^\top$$

因此奇异值的平方等于 eigenvalues

- padding 版本 (扩展为方阵)

$$A = U_{n \times n} D_{n \times m} V_{m \times m}^\top$$

1.3.2 Uses

- 确定矩阵秩
- 求 pseudo-inverse:

$$A^+ = VD^+U^\top$$

- 最佳 rank- p 近似: Truncated SVD

$$\tilde{A} = \sum_{j=1}^p D_{jj} u_j v_j^\top$$

根据 Eckart–Minsky–Young 定理, 这是 Frobenius norm 下的最优 rank- p 逼近

- 在图像压缩、聚类、推荐系统中广泛使用 (如 Netflix Prize)

1.3.3 Interpretation as basis transformation

- 作用 $UDV^\top x$ 可理解为:
 1. $V^\top x$: 在 V 的基底中表达 x
 2. D : 按奇异值缩放
 3. U : 将结果映射到 U 的列空间
- 是两个正交基之间的线性变换

1.4 Computation

1.4.1 Golub–Reinsch algorithm (经典 SVD)

- 通过一系列 Householder 变换将 A 化为 upper bidiagonal 矩阵 $A^{(0)}$
 - 右乘去掉上三角
 - 左乘去掉下三角
- 之后通过一系列 Givens rotations 把 $A^{(j)}$ 迭代逼近对角矩阵 D

|| \$ \$

$$A^{\{j+1\}} \xrightarrow{\text{R}^{\text{top}} A^{\{j\}} T}$$

- U 是所有 pre-multiplication 的积
- V 是所有 post-multiplication 的积
- 最后调整符号（保证奇异值非负）并按降序排序

1.5 Computation for large tall-skinny matrices

- 若 X 是 $n \times p$ 且 $n \gg p$ 可以先做 QR:

$$X = QR$$

- 然后对较小的 $p \times p$ 的 R 做 SVD:

$$R = UDV^\top$$

- 从而

$$X = QUDV^\top = U^*DV^\top$$

- 优点
 - 最耗时的部分变成 tall-skinny QR，可高效并行
 - SVD 部分仅对 $p \times p$ 矩阵，计算量大幅减少
 - 适合大规模数据矩阵（如文本、图像、高维特征）